

# Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Arthur Santos de Oliveira (RA: 156297)

Repositório / Código Reprodutível:

<https://github.com/Arthur-so/introducao-a-redes-neurais>

## 1. Configuração Experimental e Reprodutibilidade

### 1.1. Pré-processamento e Partição dos Dados

O conjunto contém 300 pares  $(x, y)$ , com  $x$  uniformemente espaçado em  $[0, 10]$  e  $y \in [-1,49, 2,66]$ . A partição seguiu estritamente a proporção exigida: **10% treino (30 pontos)**, **10% validação (30 pontos)** e **80% teste (240 pontos)**, por permutação aleatória com semente fixa (42).

Aplicou-se **padronização  $z$ -score** a  $x$  e a  $y$ . Sem ela, o SGD padrão converge de forma extremamente lenta: não havendo momentum nem taxa adaptativa, nenhum mecanismo compensa uma entrada mal escalonada. A média e o desvio foram calculados (*fit*) **exclusivamente sobre os 30 pontos de treino**, aplicando-se somente a transformação às partições de validação e teste, evitando vazamento de dados. Todas as métricas reportadas foram convertidas de volta à escala original de  $y$  (fator  $\sigma_{\text{treino}}^2 = 0,3688$ ).

A Tabela 1 mostra que as partições têm dispersões distintas, o que tem consequência direta na interpretação: como o  $R^2$  é normalizado pela variância do conjunto em que é medido, **valores de  $R^2$  não são comparáveis entre partições**.

Tabela 1: Estatísticas das partições.

| Partição  | $n$ | Média de $y$ | Desvio de $y$ |
|-----------|-----|--------------|---------------|
| Treino    | 30  | 0,432        | 0,607         |
| Validação | 30  | 0,415        | 0,875         |
| Teste     | 240 | 0,476        | 0,718         |

**Referências de desempenho.** Antes de treinar qualquer rede, estabeleceram-se três referências, sem as quais um MSE isolado não é interpretável (valores na escala padronizada, medidos na validação): prever sempre a média do treino resulta em  $\text{MSE} = 2,078$  (piso de utilidade); uma rede sobredimensionada com Adam, treinada apenas nos 30 pontos, atinge 0,903; e a mesma rede treinada nos 300 pontos atinge 0,239, o que estima o **piso de ruído** dos dados. O desvio do ruído foi estimado independentemente em  $\sigma \approx 0,42$  pelas diferenças entre pontos consecutivos. Conclui-se que o  $R^2$  **máximo alcançável neste conjunto situa-se entre 0,67 e 0,83**: o restante é ruído irreprodutível.

### 1.2. Definição de “Vanilla” e Conformidade

O enunciado exige uma “MLP básica” e proíbe “momentum, regularizações, etc.” no *baseline*. Adotou-se a seguinte fronteira: são **hiperparâmetros livres** o número de camadas e neurônios, a função de ativação, a taxa de aprendizado, o tamanho de lote e o número de épocas — todos fazem parte de “encontrar o melhor modelo”. São **componentes proibidos** momentum, L1, L2, *dropout*, agendamento de taxa, normalização em lote e otimizadores adaptativos.

O *early stopping* foi classificado como componente proibido e removido do *baseline*. Interromper o treino (ou restaurar os pesos da melhor época) com base no erro de validação é uma técnica de regularização, tratada como tal na literatura padrão [1]. Uma versão preliminar deste trabalho restaurava os pesos da melhor época; ao identificar a inconsistência com o enunciado, o mecanismo foi removido e **toda a seleção de hiperparâmetros foi refeita**, pois havia sido conduzida sob protocolo distinto. A mudança não foi cosmética: a arquitetura, a ativação, a taxa de aprendizado, o lote e o orçamento de épocas **todos se alteraram** (Seção 4.1). No protocolo final, os pesos entregues são os da **última época**, com orçamento fixo e idêntico para todas as configurações.

Registram-se duas fronteiras discutíveis, por transparência. Primeira, a padronização dos dados: classificada como pré-processamento, não como componente do modelo, pois não restringe a capacidade da rede nem altera a função objetivo. Segunda, a escolha do número de épocas pela validação: distingue-se do *early stopping* por ser um **orçamento fixo**, idêntico para todas as configurações e sementes, e não um critério adaptativo aplicado a cada execução. A Seção 3 mostra que essa distinção tem consequências práticas relevantes.

### 1.3. Otimização Empírica do Modelo Baseline

A busca foi conduzida por **varredura em grade**, em estágios sucessivos para evitar explosão combinatoria, avaliando-se sempre pelo **menor erro de validação na época final**. O conjunto de teste não participou de nenhuma decisão de modelagem.

Tabela 2: Espaço amostrado e configuração final da MLP Baseline (Vanilla).

| Hiperparâmetro        | Valores Explorados                                                         | Escolhido (Vanilla)                                            |
|-----------------------|----------------------------------------------------------------------------|----------------------------------------------------------------|
| Topologia das Camadas | 1, 2 e 3 camadas; 4, 8, 16, 32, 64 e 128 neurônios (18 combinações)        | $1 \rightarrow 64 \rightarrow 64 \rightarrow 64 \rightarrow 1$ |
| Formato das Camadas   | Uniforme, afunilado, expansivo, gargalo, 4 camadas (11 formatos)           | Uniforme                                                       |
| Função de Ativação    | ReLU, Tanh                                                                 | ReLU                                                           |
| Otimizador            | SGD padrão ( <b>momentum</b> = 0,0, <b>weight decay</b> = 0,0)             | SGD ( $\eta = 0,01$ )                                          |
| Taxa de Aprendizagem  | 0,01; 0,03; 0,1; 0,3                                                       | 0,01                                                           |
| Tamanho do Lote       | 8, 16, 30                                                                  | 8                                                              |
| Número de Épocas      | 5.000; 10.000; 15.000; 20.000; 25.000; 30.000                              | 10.000                                                         |
| Função de Custo       | Erro Quadrático Médio                                                      | MSELoss                                                        |
| Critério de Parada    | <b>Nenhum</b> — orçamento fixo de épocas (ver Seção 1.2)                   | Últimos pesos                                                  |
| Semente Aleatória     | Partição: 42. Inicialização: 0, 1, 2 (idênticas em todas as configurações) | —                                                              |

O modelo final possui **8.513 parâmetros** para 30 amostras de treino — 284 parâmetros por amostra, o que torna o sobreajuste inevitável e central à análise.

**Estágio 1 — Topologia.** As 18 combinações de largura e profundidade foram avaliadas com 3 sementes e as cinco melhores reconfirmadas com 8 sementes (Tabela 3). As três primeiras **empatam estatisticamente** (teste  $t$  de Welch contra a líder:  $t = 1,17$  e  $t = 1,18$ ), enquanto a  $16 \times 3$  ( $t = 2,62$ ) e a  $32 \times 3$  ( $t = 4,71$ ) são significativamente piores. Selecionou-se a  **$64 \times 3$**  entre as empatadas por apresentar o **menor desvio entre sementes no teste de toda a varredura** ( $\pm 0,013$ ), ou seja, maior reprodutibilidade — critério natural quando o desempenho empata. Registra-se que o menor erro de validação absoluto foi da  $128 \times 3$ , e que a escolha repousa sobre empate estatístico somado a reprodutibilidade, não sobre superioridade medida.

Tabela 3: Erros de treino e validação das arquiteturas candidatas a *baseline* (8 sementes, escala padronizada; MSE de teste incluído apenas para referência, não utilizado na seleção).

| Arquitetura                     | Parâmetros   | MSE treino  | MSE validação                       | MSE teste                           |
|---------------------------------|--------------|-------------|-------------------------------------|-------------------------------------|
| $128 \times 3$                  | 33.409       | 0,12        | $1,029 \pm 0,087$                   | $0,377 \pm 0,033$                   |
| $8 \times 2$                    | 97           | 0,41        | $1,075 \pm 0,070$                   | $0,404 \pm 0,034$                   |
| <b><math>64 \times 3</math></b> | <b>8.513</b> | <b>0,16</b> | <b><math>1,098 \pm 0,141</math></b> | <b><math>0,377 \pm 0,013</math></b> |
| $16 \times 3$                   | 593          | 0,29        | $1,182 \pm 0,141$                   | $0,384 \pm 0,043$                   |
| $32 \times 3$                   | 2.209        | 0,21        | $1,240 \pm 0,092$                   | $0,407 \pm 0,036$                   |

**Estágio 2 — Formato das camadas.** O enunciado não exige largura uniforme, e tratá-la como valor único aplicado a todas as camadas é uma suposição que reduz a busca de  $N$  dimensões para 2. Ela foi testada explicitamente: 11 formatos alternativos, 6 sementes cada. O uniforme ( $64-64-64$ ; validação  $1,045 \pm 0,051$ ) **empata com o melhor formato encontrado**, o gargalo  $64-16-64$  ( $1,033 \pm 0,068$ ;  $t = 0,35$ ), e os MSE de teste são idênticos até a quarta casa decimal ( $0,3767$  contra  $0,3764$ ). Um

achado contraria o senso comum: os **formatos afunilados foram sistematicamente piores** (96-48-24: 1,277; 64-32-16: 1,329; 128-64-32-16: 1,337), apesar de a intuição usual sugerir que camadas largas extraíam características e as seguintes as comprimam até a saída escalar.

**Estágio 3 — Ativação, taxa, lote e épocas.** Avaliaram-se 12 combinações com 4 sementes, cada uma em 6 orçamentos de época, e os finalistas foram reconfirmados com 8 sementes. **As três primeiras posições foram todas ReLU**; a diferença para o melhor Tanh não é significativa ( $t = 1,19$ ), mas o ReLU apresenta desvio entre sementes de 0,03–0,04 contra 0,11–0,14 do Tanh, sendo portanto cerca de **três vezes mais reprodutível**. Com três camadas, a saturação do Tanh atenua os gradientes retropropagados (gradiente evanescente), efeito que o ReLU não sofre por ter derivada unitária na região ativa.

**O orçamento de épocas revelou-se hiperparâmetro de primeira ordem.** Sem *early stopping*, quase toda combinação apresenta curva de validação em U — o erro melhora, atinge um mínimo e volta a subir (Tabela 4). Treinar além do mínimo produz apenas sobreajuste.

Tabela 4: Erro de validação por orçamento de épocas (rede 64×3, 4 sementes, escala padronizada). O mínimo de cada linha está em negrito.

| Configuração                  | 5.000 | 10.000       | 15.000       | 20.000 | 25.000 | 30.000       |
|-------------------------------|-------|--------------|--------------|--------|--------|--------------|
| ReLU, $\eta = 0,01$ , lote 8  | 1,076 | <b>0,933</b> | 0,951        | 0,997  | 1,037  | 1,047        |
| Tanh, $\eta = 0,03$ , lote 8  | 1,087 | 0,957        | <b>0,950</b> | 0,990  | 1,016  | 1,036        |
| Tanh, $\eta = 0,01$ , lote 16 | 1,456 | 1,267        | 1,158        | 1,128  | 1,083  | <b>0,991</b> |

Observa-se ainda uma **inversão instrutiva**:  $\eta = 0,1$  era a melhor taxa enquanto havia *early stopping* — convergir rápido não tinha custo, pois os melhores pesos eram restaurados ao final. Sem esse mecanismo, taxa alta significa sobreajustar mais depressa, e  $\eta = 0,1$  tornou-se a pior opção testada (validação de 1,26 a 1,50). Hiperparâmetros não são independentes do protocolo de treino.

## 2. Dinâmica de Treinamento e Convergência




Figura 1: Esquerda: evolução do MSE de treino e validação do *baseline* (escala padronizada, eixo logarítmico). A curva clara é o valor bruto por época e a linha escura é a média móvel de 101 épocas. Direita: ajuste obtido sobre os dados de teste.

**Estabilidade do SGD.** A alta variância visível nas curvas brutas da Figura 1 decorre da combinação de lote pequeno (8 amostras) com conjunto de treino diminuto (30 pontos): são apenas 4 atualizações por época, cada uma baseada em uma amostra ruidosa do gradiente. Sem momentum, não há acumulação de direção que suavize essas oscilações — é precisamente essa a função que o momentum desempenharia. A taxa de aprendizado mostrou-se o fator decisivo de estabilidade: em experimentos com  $\eta = 0,3$  o treino **divergiu numericamente em todas as sementes**, e com  $\eta = 0,1$  combinado a momentum  $\geq 0,7$  em arquiteturas de três camadas observaram-se divergências (perda tendendo a




Figura 2: Comparação direta das curvas de validação: *baseline* contra os modelos com componentes adicionais.

NaN). A escolha de  $\eta = 0,01$  mantém o treino em regime estável em toda a faixa de momentum testada.

**Sobreajuste.** O descolamento entre treino e validação é precoce e permanente. A perda de treino cai continuamente até  $\approx 0,16$  (escala padronizada), enquanto a validação estabiliza em torno de 0,95 a partir da época 4.000 — uma razão de aproximadamente  $6\times$ . Na escala original, isso corresponde a  $R^2 = 0,843$  no treino contra 0,288 no teste. Com 284 parâmetros por amostra de treino, a rede tem capacidade de sobra para memorizar os 30 pontos, e o faz.

**Aceleração com momentum.** O momentum reduziu substancialmente o número de épocas até a convergência: de 7.939 no *baseline* para 2.884 com  $\beta = 0,9$ , uma redução de 64% (Tabela 5), confirmando seu papel como acelerador. Entretanto, **essa aceleração não se converteu em melhor generalização**: o erro final permaneceu estatisticamente indistinguível do *baseline*. Em um experimento anterior, com orçamento de épocas insuficiente, o momentum aparentava ser o melhor componente de todos (melhora de 11% no MSE de teste); ao estender o orçamento, a vantagem desapareceu por completo, revelando que ela era artefato de subtreino do *baseline*, e não mérito do componente.

### 3. Estudo de Ablação e Desempenho no Conjunto de Teste

Para isolar o efeito de cada componente, **a arquitetura foi mantida idêntica** à da Tabela 2 — mesmas camadas, mesmos neurônios, mesma ativação — variando-se exclusivamente o componente em estudo. A comparação é **pareada**: verificou-se empiricamente que *baseline* e ablações partem de **pesos iniciais idênticos** e, para L1, L2 e momentum, percorrem a **mesma sequência de minilotes**, sendo os resultados reprodutíveis bit a bit. A única exceção é o *dropout*, que consome números aleatórios ao sortear máscaras e portanto diverge da sequência a partir do primeiro sorteio — limitação inerente ao método.

Cada configuração foi executada com **3 sementes** e os valores reportados são médias. As grades de intensidade foram construídas de modo a **cercar o ótimo**: o melhor valor deve ter vizinhos piores dos dois lados, caso contrário a grade estaria incompleta.

**Nenhum componente melhorou o *baseline*.** O melhor resultado da ablação é o L1 com  $\lambda = 10^{-4}$ , que reduz o MSE de teste em 0,0007 — dois décimos de por cento, indistinguível de ruído frente ao

Tabela 5: Estudo de ablação no conjunto de teste (240 pontos, 80% dos dados). Médias de 3 sementes, métricas na escala original de  $y$ . “Épocas até convergência” é a primeira época em que a validação suavizada entra a 2% do seu mínimo.

| Modelo / Variação                           | MSE           | RMSE          | MAE           | $R^2$         | Épocas até conv. |
|---------------------------------------------|---------------|---------------|---------------|---------------|------------------|
| <b>Baseline Vanilla (SGD sem momentum)</b>  | <b>0,3527</b> | <b>0,5938</b> | <b>0,4620</b> | <b>0,3158</b> | 7.939            |
| <i>Regularização L1</i>                     |               |               |               |               |                  |
| $\lambda = 10^{-5}$                         | 0,3559        | 0,5964        | 0,4644        | 0,3096        | 7.501            |
| $\lambda = 10^{-4}$                         | 0,3520        | 0,5930        | 0,4614        | 0,3171        | 7.267            |
| $\lambda = 10^{-3}$                         | 0,3844        | 0,6197        | 0,4900        | 0,2543        | 7.865            |
| <i>Regularização L2 (weight decay)</i>      |               |               |               |               |                  |
| $\lambda = 10^{-5}$                         | 0,3553        | 0,5959        | 0,4642        | 0,3107        | 7.418            |
| $\lambda = 10^{-4}$                         | 0,3569        | 0,5972        | 0,4648        | 0,3078        | 7.346            |
| $\lambda = 10^{-3}$                         | 0,3590        | 0,5990        | 0,4673        | 0,3036        | 7.695            |
| $\lambda = 10^{-2}$                         | 0,4503        | 0,6710        | 0,5295        | 0,1265        | 7.281            |
| <i>Dropout</i>                              |               |               |               |               |                  |
| $p = 0,1$                                   | 0,3943        | 0,6277        | 0,5006        | 0,2351        | 8.959            |
| $p = 0,2$                                   | 0,4081        | 0,6386        | 0,5115        | 0,2083        | 7.655            |
| $p = 0,3$                                   | 0,4386        | 0,6622        | 0,5347        | 0,1492        | 7.231            |
| <i>Momentum</i>                             |               |               |               |               |                  |
| $\beta = 0,3$                               | 0,3534        | 0,5944        | 0,4624        | 0,3144        | 6.369            |
| $\beta = 0,5$                               | 0,3571        | 0,5975        | 0,4650        | 0,3073        | 4.201            |
| $\beta = 0,7$                               | 0,3603        | 0,6001        | 0,4629        | 0,3010        | 5.087            |
| $\beta = 0,9$                               | 0,3588        | 0,5989        | 0,4638        | 0,3040        | <b>2.884</b>     |
| <i>Combinações dos melhores componentes</i> |               |               |               |               |                  |
| L1 $10^{-4}$ + mom. 0,3                     | 0,3645        | 0,6036        | 0,4690        | 0,2930        | 5.373            |
| L2 $10^{-5}$ + mom. 0,3                     | 0,3556        | 0,5962        | 0,4638        | 0,3102        | 5.789            |
| L1 $10^{-4}$ + L2 $10^{-5}$                 | 0,3573        | 0,5975        | 0,4662        | 0,3069        | 7.716            |
| L1 + L2 + mom.                              | 0,3648        | 0,6039        | 0,4693        | 0,2924        | 5.124            |

desvio entre sementes. As **combinações também não ajudaram**: a melhor delas (L2 + momentum) fica 0,0029 acima do *baseline*. E, diferentemente de experimentos preliminares, **as duas métricas concordam**: na validação — o critério de seleção — o *baseline* apresenta o menor erro de todos (0,9465), abaixo de qualquer configuração aditivada.

**Por que nada funcionou.** O orçamento de 10.000 épocas foi selecionado como o mínimo da curva de validação (Tabela 4), o que posiciona o *baseline* exatamente no ponto de equilíbrio entre subajuste e sobreajuste. A regularização existe para *deslocar* esse ponto; com o orçamento já ajustado ao mínimo, ela apenas restringe um modelo que já se encontra bem posicionado. Trata-se do mesmo mecanismo do *early stopping* reaparecendo sob outra forma: **ajustar o número de épocas pela validação captura o benefício que a regularização ofereceria**. Esta é a consequência prática da fronteira discutível declarada na Seção 1.2 — e sugere que, tivesse o orçamento sido fixado arbitrariamente em valor alto, L1 e L2 teriam apresentado ganho aparente que, na verdade, seria apenas compensação de um orçamento mal escolhido.

**Comportamento por componente.** *L1* e *L2* são neutros em intensidades fracas e destrutivos em intensidades fortes: L2 com  $\lambda = 10^{-2}$  derruba o  $R^2$  de 0,32 para 0,13, pois a penalização passa a dominar a função objetivo e a rede subajusta. Não se observou a diferença qualitativa esperada entre L1 (indução à esparsidade) e L2 (atenuação de pesos grandes) — ambos degradam de forma semelhante conforme  $\lambda$  cresce, o que é coerente com o diagnóstico de que a limitação é o volume de dados, não a magnitude dos pesos. O *dropout* é claramente prejudicial e piora **monotonicamente** com a taxa ( $0,394 \rightarrow 0,408 \rightarrow 0,439$ ): ele força a rede a não depender de neurônios individuais, o que exige redundância, e redundância exige dados; com 30 amostras, remove sinal em vez de ruído. Ressalve-se que sua curva de validação **ainda descia ao final do orçamento** (Figura 2), de modo que o orçamento fixo o penaliza.

O *momentum* acelera sem melhorar. É o resultado mais nítido da ablação:  $\beta = 0,9$  atinge a convergência em **2.884 épocas contra 7.939 do *baseline***, uma redução de **64%**, chegando entretanto a um erro final estatisticamente indistinguível (0,3588 contra 0,3527). A Figura 2 mostra o fenômeno graficamente: a curva do momentum descende mais rapidamente nas primeiras épocas, mas o *baseline* a alcança e termina ligeiramente abaixo. O momentum resolve o problema que o SGD puro possui — lentidão em vales estreitos da superfície de erro — sem alterar a qualidade da solução encontrada.




Figura 3: Evolução do treinamento para o *baseline* e configurações representativas de cada componente.




Figura 4: Esquerda: dispersão real *versus* predito no teste, com a reta  $y = x$ . Direita: resíduos ( $y - \hat{y}$ ) em função do valor predito.

#### 4. Discussão e Lições Aprendidas

**Sobreajuste no regime de poucos dados.** Com 30 amostras de treino, o fator limitante não é a arquitetura, e sim o volume de dados. A evidência é direta: arquiteturas de 97 a 33.409 parâmetros — uma variação de 344× — produziram MSE de teste entre 0,377 e 0,407, uma diferença de cerca de 1% da amplitude de  $y$ . Nenhuma escolha de topologia rompe esse teto.

**Análise de resíduos.** A Figura 4 revela **atenuação** acentuada: o ajuste linear de predito contra real tem inclinação 0,463, quando o ideal seria 1,0, e as previsões cobrem apenas **60% da amplitude real** ( $[-1,17, 1,29]$  contra  $[-1,49, 2,66]$ ). Os resíduos apresentam estrutura sistemática por faixa:  $-0,242$  nos valores baixos de  $y$ ,  $+0,157$  nos médios e  $+0,737$  nos altos. O modelo **subestima sistemática-**

**mente os extremos superiores.** Trata-se de regressão à média: sob ruído elevado ( $\sigma \approx 0,42$ ) e poucos dados, prever próximo à média minimiza o erro quadrático esperado, ao custo de sacrificar as caudas. Esse padrão **persiste em todos os modelos regularizados** — nenhuma das técnicas de ablação o corrigiu, pois nenhuma ataca sua causa, que é a escassez de dados.

**Perspectiva realista de desempenho.** O  $R^2$  de teste de 0,288 deve ser lido contra o teto estimado de 0,67–0,83 imposto pelo ruído dos dados. O modelo recupera, portanto, cerca de **40% do sinal aprendível**, e não 29% de um ideal de 100%. O restante não é falha do modelo: é ruído irreprodutível.

#### 4.1. Trajetória do Desenvolvimento e Revisões

Três decisões foram revistas durante o trabalho, e os motivos são instrutivos.

**O *early stopping* foi identificado como violação do enunciado.** Versões iniciais restauravam os pesos da melhor época de validação. Como as escolhas de hiperparâmetros haviam sido feitas sob esse protocolo, removê-lo exigiu refazer toda a seleção — e ela de fato mudou: arquitetura de  $32 \times 3$  para  $64 \times 3$ , ativação de Tanh para ReLU, taxa de 0,1 para 0,01, lote de 16 para 8 e orçamento de 30.000 para 10.000 épocas. A configuração final é **significativamente melhor** que a anterior na validação ( $t = 2,63$ ), de modo que a correção de conformidade trouxe também ganho de desempenho.

**A largura uniforme era suposição não declarada.** Detectada e testada explicitamente (Estágio 2), confirmou-se inofensiva — mas isso só é afirmável porque foi medido.

**Diferenças aparentes desapareceram ao aumentar o número de sementes.** Em três ocasiões uma configuração parecia superior com 3 sementes e perdia a vantagem com 6 ou 8. A arquitetura  $16 \times 3$ , por exemplo, aparecia em segundo lugar (validação 1,037) e caiu para quarto (1,182) ao ser reavaliada. Por isso todas as decisões finais reportam desvio-padrão e teste  $t$ , e não apenas a média.

#### 4.2. Limitações

- **Validação com 30 pontos é frágil** para seleção de modelos. As diferenças entre as arquiteturas do topo não são estatisticamente significativas, de modo que a escolha final repousa sobre empate somado a critério de reprodutibilidade. O remédio adequado seria **validação cruzada  $k$ -fold** sobre treino e validação, eliminando a dependência de um único corte; não foi realizada por custo computacional.
- **A busca foi por estágios, não conjunta.** Trata-se de otimização por coordenadas com uma única passada, que não garante o ótimo global do espaço conjunto de hiperparâmetros.
- **O orçamento fixo de épocas penaliza componentes de convergência mais lenta**, o *dropout* em particular, cuja curva de validação ainda descia ao final do orçamento.
- **Métricas de execução única.** Os gráficos ilustrativos provêm de uma semente; as tabelas de ablação usam média de três e são mais confiáveis.

#### Referências

- [1] I. Goodfellow, Y. Bengio e A. Courville. *Deep Learning*. MIT Press, 2016. Capítulo 7.8, “Early Stopping as a Regularizer”.