

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Arthur Santos de Oliveira (RA: 156297)

Repositório / Código Reprodutível:

<https://github.com/Arthur-so/introducao-a-redes-neurais>

1. Configuração Experimental

1.1. Pré-processamento e Partição dos Dados

O conjunto possui 300 pares (x, y) , com $x \in [0, 10]$ e $y \in [-1,49; 2,66]$. A partição seguiu a proporção exigida: **10% treino (30 pontos)**, **10% validação (30 pontos)** e **80% teste (240 pontos)**, com semente fixa (42) para que a divisão seja sempre a mesma.

Os valores de x e y foram **padronizados** (média zero e desvio unitário), pois sem isso o SGD puro converge muito lentamente. A média e o desvio foram calculados **apenas com os dados de treino** e depois aplicados à validação e ao teste, evitando vazamento de informação. Todas as métricas deste relatório estão na escala original de y .

Referências de desempenho. Um MSE isolado não diz se o resultado é bom. Por isso, antes de treinar o *baseline*, mediram-se três referências no conjunto de teste (Tabela 1). O otimizador Adam foi usado apenas nessas medições auxiliares, nunca nos modelos do trabalho.

Tabela 1: Referências de desempenho no conjunto de teste.

Referência	MSE	Significado
Prever sempre a média do treino	0,518	Modelo trivial, que ignora x
Rede grande + Adam, apenas os 30 pontos de treino	0,355	Melhor resultado esperado com tão poucos dados
Rede grande + Adam, todos os 300 pontos	0,142	Ruído dos dados: nenhum modelo fica abaixo disso

A última linha mostra que, mesmo vendo todos os dados, sobra um erro: é ruído aleatório, impossível de prever a partir de x . Portanto, neste problema, o R^2 nunca chegaria a 1.

1.2. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O *baseline* é uma MLP básica treinada com **SGD padrão**, sem Adam, sem *momentum* e sem regularização (L1, L2, *dropout*). O *early stopping* também foi excluído, por ser uma forma de regularização: o modelo final usa os pesos da **última época**, com número de épocas fixo e igual para todas as configurações.

A busca empírica foi feita em **três etapas**, sempre escolhendo pelo **menor erro na validação** (o teste não foi usado em nenhuma escolha): (1) número de camadas e de neurônios; (2) formato das camadas; (3) função de ativação, taxa de aprendizado, tamanho de lote e número de épocas. Em cada etapa, os hiperparâmetros das outras etapas ficaram fixos. A Tabela 2 resume os valores testados e a configuração escolhida.

Tabela 2: Valores explorados e configuração final do *baseline*.

Hiperparâmetro	Valores explorados	Escolhido
Camadas ocultas	1, 2 e 3	3
Neurônios por camada	4, 8, 16, 32, 64 e 128	64
Formato das camadas	Uniforme, afunilado, expansivo, gargalo	Uniforme (64-64-64)
Função de ativação	ReLU, Tanh	ReLU
Otimizador	SGD padrão (sem <i>momentum</i> e sem regularização)	SGD
Taxa de aprendizado	0,01; 0,03; 0,1; 0,3	0,01
Tamanho do lote	8, 16, 30	8
Número de épocas	5.000 a 30.000	10.000
Função de custo	Erro quadrático médio (MSE)	MSE

O modelo final possui **8.513 parâmetros**.

Repetições. Os pesos iniciais da rede são sorteados, e esse sorteio muda bastante o resultado: o mesmo *baseline*, trocando apenas a semente, teve erro de validação entre 0,326 e 0,361 — uma variação de 11%, maior do que várias das diferenças que queríamos medir. Por isso, **cada configuração foi treinada três vezes** (sementes 0, 1 e 2, as mesmas para todas as configurações) e reporta-se a média. Quando a diferença entre dois modelos é menor que essa variação entre repetições, eles são considerados **empatados**. Nas escolhas mais importantes, como a arquitetura, foram usadas 8 repetições.

Etapa 1 — Arquitetura. As cinco melhores arquiteturas estão na Tabela 3. As três primeiras ficaram empatadas: as diferenças entre elas são menores que a variação entre repetições. Escolheu-se a **64×3** por ter a **menor variação entre repetições no teste** (ou seja, ser a mais estável) e por ter tamanho intermediário.

Tabela 3: Melhores arquiteturas (média $\pm$ variação entre 8 repetições). Nesta etapa os demais hiperparâmetros ainda estavam fixos (Tanh, taxa 0,1, lote 16), por isso os valores diferem do resultado final.

Arquitetura	Parâmetros	MSE validação	MSE teste
128×3	33.409	0,380 $\pm$ 0,032	0,377 $\pm$ 0,033
8×2	97	0,396 $\pm$ 0,026	0,404 $\pm$ 0,034
64×3	8.513	0,405 $\pm$ 0,052	0,377 $\pm$ 0,013
16×3	593	0,436 $\pm$ 0,052	0,384 $\pm$ 0,043
32×3	2.209	0,457 $\pm$ 0,034	0,407 $\pm$ 0,036

Etapa 2 — Formato das camadas. Além de camadas com o mesmo número de neurônios, testaram-se formatos afunilados (ex.: 128-64-32), expansivos (ex.: 32-64-128) e com gargalo (64-16-64). O formato uniforme empatou com o melhor deles, e os formatos afunilados foram os piores.

Etapa 3 — Ativação, taxa, lote e épocas. A **ReLU** teve erro menor que a **Tanh** (0,354 contra 0,373 na validação) e variou cerca de três vezes menos entre repetições. A melhor combinação foi **taxa 0,01 com lote 8**. Quanto às épocas, o erro de validação diminui até certo ponto e depois volta a subir, porque o modelo passa a decorar o treino (Tabela 4). O menor erro ocorreu em **10.000 épocas**.

Tabela 4: Erro de validação (MSE) por número de épocas, para a configuração final.

5.000	10.000	15.000	20.000	25.000	30.000
0,397	0,344	0,351	0,368	0,383	0,386

Resultado do baseline. A Tabela 5 mostra os erros de treino, validação e teste do modelo escolhido (uma execução, semente 0).

O erro no treino é muito menor que na validação e no teste, o que indica **sobreajuste**: a rede aprende bem os 30 pontos de treino, mas generaliza pior. (O R^2 da validação parece melhor que o do teste porque cada conjunto tem uma dispersão diferente; em MSE, os dois são parecidos.)

Tabela 5: Métricas do <i>baseline</i> final.				
Conjunto	MAE	MSE	RMSE	R^2
Treino	0,168	0,058	0,241	0,843
Validação	0,479	0,334	0,578	0,565
Teste	0,466	0,367	0,606	0,288

2. Dinâmica de Treinamento e Convergência




Figura 1: Esquerda: erro de treino e validação do *baseline* ao longo das épocas (escala padronizada). Direita: curva aprendida sobre os dados de teste.

- **Estabilidade do SGD:** as curvas oscilam bastante porque cada atualização usa apenas 8 amostras. Taxas de aprendizado altas (0,3) fizeram o treino divergir; com 0,01 o treino foi estável.
- **Sobreajuste:** a partir de cerca de 4.000 épocas, o erro de treino continua caindo enquanto o de validação fica estável. A diferença entre os dois é visível na Figura 1.
- **Momentum:** acelerou bastante a convergência — com $\beta = 0,9$ foram necessárias cerca de 2.900 épocas, contra 7.900 do *baseline* (64% menos) —, mas o erro final foi praticamente o mesmo (Figura 2).




Figura 2: Erro de validação do *baseline* comparado aos modelos com componentes adicionais.

3. Estudo de Ablação e Desempenho no Conjunto de Teste

Cada componente foi adicionado ao *baseline* sem mudar sua arquitetura, usando as mesmas sementes. Para cada componente, testaram-se diferentes intensidades, e também combinações dos melhores. A Tabela 6 mostra os resultados no teste (média de 3 repetições).

Tabela 6: Estudo de ablação no conjunto de teste (média de 3 repetições). “Épocas até convergir” indica quando o erro de validação se estabiliza.

Modelo	MSE	RMSE	MAE	R^2	Épocas até convergir
Baseline (SGD sem momentum)	0,3527	0,5938	0,4620	0,3158	7.939
L1 ($\lambda = 10^{-5}$)	0,3559	0,5964	0,4644	0,3096	7.501
L1 ($\lambda = 10^{-4}$)	0,3520	0,5930	0,4614	0,3171	7.267
L1 ($\lambda = 10^{-3}$)	0,3844	0,6197	0,4900	0,2543	7.865
L2 ($\lambda = 10^{-5}$)	0,3553	0,5959	0,4642	0,3107	7.418
L2 ($\lambda = 10^{-4}$)	0,3569	0,5972	0,4648	0,3078	7.346
L2 ($\lambda = 10^{-3}$)	0,3590	0,5990	0,4673	0,3036	7.695
L2 ($\lambda = 10^{-2}$)	0,4503	0,6710	0,5295	0,1265	7.281
Dropout ($p = 0,1$)	0,3943	0,6277	0,5006	0,2351	8.959
Dropout ($p = 0,2$)	0,4081	0,6386	0,5115	0,2083	7.655
Dropout ($p = 0,3$)	0,4386	0,6622	0,5347	0,1492	7.231
Momentum ($\beta = 0,3$)	0,3534	0,5944	0,4624	0,3144	6.369
Momentum ($\beta = 0,5$)	0,3571	0,5975	0,4650	0,3073	4.201
Momentum ($\beta = 0,7$)	0,3603	0,6001	0,4629	0,3010	5.087
Momentum ($\beta = 0,9$)	0,3588	0,5989	0,4638	0,3040	2.884
L2 + momentum	0,3556	0,5962	0,4638	0,3102	5.789
L1 + momentum	0,3645	0,6036	0,4690	0,2930	5.373
L1 + L2	0,3573	0,5975	0,4662	0,3069	7.716
L1 + L2 + momentum	0,3648	0,6039	0,4693	0,2924	5.124

Nenhum componente melhorou o *baseline*. O melhor resultado (L1 com $\lambda = 10^{-4}$) reduziu o MSE em apenas 0,0007, valor muito menor que a variação entre repetições. As combinações também não ajudaram. No conjunto de validação, o *baseline* teve o menor erro de todos (0,349).

Por quê. O número de épocas do *baseline* foi escolhido exatamente no ponto de menor erro de

validação. Com isso, ele já está no equilíbrio entre aprender pouco e decorar o treino, e a regularização, cuja função é justamente evitar que o modelo decore, não tem mais o que corrigir.

Por componente:

- **L1 e L2:** com valores pequenos, quase não mudam nada; com valores grandes, pioram o modelo (L2 com $\lambda = 10^{-2}$ derruba o R^2 de 0,32 para 0,13), pois a penalização impede a rede de aprender.
- **Dropout:** piorou o resultado em todas as intensidades, e quanto maior a taxa, pior. Com apenas 30 pontos de treino, desligar neurônios remove informação útil. Ele também converge mais devagar.
- **Momentum:** não mudou o erro final, mas fez o treino convergir muito mais rápido.

Análise dos erros. A Figura 3 compara, para cada ponto de teste, o valor real com o valor previsto. Se o modelo acertasse tudo, todos os pontos ficariam sobre a linha tracejada. O que se observa é que **as previsões ficam mais próximas da média do que os valores reais**: o modelo acerta bem os valores intermediários, mas erra os extremos, principalmente os mais altos. Por exemplo, para o maior valor real do teste (2,66), o modelo previu 0,77; e, enquanto os valores reais vão de $-1,49$ a $2,66$, as previsões ficam entre $-1,17$ e $1,29$. No gráfico da direita, os pontos acima da linha zero são casos em que o modelo previu **abaixo** do valor real. Esse comportamento é esperado com poucos dados e muito ruído: prever perto da média é a forma de errar menos em média, ao custo de errar mais nos extremos. Nenhum dos componentes testados corrigiu isso.




Figura 3: Esquerda: valor real *versus* previsto no teste (a linha tracejada é a previsão perfeita). Direita: erro de cada previsão.

3.1. Estudo Complementar: Rede Maior

Para verificar se a regularização ajudaria num modelo com mais capacidade, a ablação foi repetida numa rede 128×3 (33.409 parâmetros, cerca de 4 vezes o *baseline*), mantendo todo o resto igual. Foram testados dois valores de cada componente (Tabela 7).

A rede maior generaliza **11% pior** que o *baseline*. Nela, L2, *dropout* leve e *momentum* passam a ter um pequeno efeito positivo, como seria esperado num modelo com capacidade de sobra — mas as diferenças são pequenas, da mesma ordem da variação entre repetições. **E nenhuma variante da rede maior superou o *baseline* 64×3** : escolher o tamanho certo da rede foi mais eficaz do que regularizar uma rede grande demais.

Tabela 7: Ablação na rede 128×3 , no conjunto de teste (média de 3 repetições).

Modelo	MSE	R^2
<i>Baseline</i> 64×3 (referência)	0,3527	0,316
Rede 128×3 sem componentes	0,3906	0,242
L1 ($\lambda = 10^{-4}$ / 10^{-3})	0,3933 / 0,4185	0,237 / 0,188
L2 ($\lambda = 10^{-4}$ / 10^{-3})	0,3852 / 0,3871	0,253 / 0,249
Dropout ($p = 0,1$ / $0,2$)	0,3892 / 0,4014	0,245 / 0,221
Momentum ($\beta = 0,5$ / $0,9$)	0,3730 / 0,3702	0,276 / 0,282

4. Discussão e Conclusões

- **O limite é a quantidade de dados.** Redes de 97 a 33.409 parâmetros tiveram resultados muito parecidos, e uma rede grande treinada com Adam nos mesmos 30 pontos obteve praticamente o mesmo erro do *baseline* (0,355 contra 0,353). Com 10% dos dados para treino, nem a arquitetura nem o otimizador mudam muito o resultado.
- **Desempenho realista.** O R^2 de teste de 0,288 parece baixo, mas, por causa do ruído dos dados, o máximo possível neste problema é em torno de 0,73. O *baseline* recupera cerca de 44% do que seria possível aprender.
- **Regularização e momentum.** No *baseline*, nenhuma técnica ajudou, porque o número de épocas já havia sido ajustado no ponto ideal. Numa rede maior, elas passam a ajudar um pouco, mas não compensam o excesso de capacidade. O *momentum* acelera o treino sem melhorar o resultado final.
- **Revisões durante o desenvolvimento.** (i) Uma versão inicial usava *early stopping*; ao removê-lo, por ser uma regularização, toda a escolha de hiperparâmetros foi refeita e mudou. (ii) Inicialmente só se testaram camadas de mesmo tamanho; outros formatos foram testados depois e não foram melhores. (iii) Algumas diferenças que pareciam reais com 3 repetições desapareceram com 8, o que mostrou a importância de repetir os experimentos.
- **Limitações.** A validação tem apenas 30 pontos, o que torna a escolha do modelo sensível ao acaso; a busca foi feita por etapas, e não testando todas as combinações possíveis; e o número fixo de épocas pode prejudicar o *dropout*, que converge mais devagar.