

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Arthur Santos de Oliveira (RA: 156297)

Repositório / Código Reprodutível:

<https://github.com/Arthur-so/introducao-a-redes-neurais>

1. Configuração Experimental e Reprodutibilidade

1.1. Pré-processamento e Partição dos Dados

O conjunto contém 300 pares (x, y) , com x uniformemente espaçado em $[0, 10]$ e $y \in [-1,49, 2,66]$. A partição seguiu estritamente a proporção exigida: **10% treino (30 pontos)**, **10% validação (30 pontos)** e **80% teste (240 pontos)**, por permutação aleatória com semente fixa (42).

Aplicou-se **padronização z -score** a x e a y . Sem ela, o SGD padrão converge de forma extremamente lenta: não havendo momentum nem taxa adaptativa, nenhum mecanismo compensa uma entrada mal escalonada. A média e o desvio foram calculados (*fit*) **exclusivamente sobre os 30 pontos de treino**, aplicando-se somente a transformação às partições de validação e teste, evitando vazamento de dados. Todas as métricas reportadas foram convertidas de volta à escala original de y (fator $\sigma_{\text{treino}}^2 = 0,3688$).

A Tabela 1 mostra que as partições têm dispersões distintas, o que tem consequência direta na interpretação: como o R^2 é normalizado pela variância do conjunto em que é medido, **valores de R^2 não são comparáveis entre partições**.

Tabela 1: Estatísticas das partições.

Partição	n	Média de y	Desvio de y
Treino	30	0,432	0,607
Validação	30	0,415	0,875
Teste	240	0,476	0,718

Referências de desempenho. Antes de treinar qualquer rede, estabeleceram-se três referências, sem as quais um MSE isolado não é interpretável (valores na escala padronizada, medidos na validação): prever sempre a média do treino resulta em $\text{MSE} = 2,078$ (piso de utilidade); uma rede sobredimensionada com Adam, treinada apenas nos 30 pontos, atinge 0,903; e a mesma rede treinada nos 300 pontos atinge 0,239, o que estima o **piso de ruído** dos dados. O desvio do ruído foi estimado independentemente em $\sigma \approx 0,42$ pelas diferenças entre pontos consecutivos. Conclui-se que o R^2 **máximo alcançável neste conjunto situa-se entre 0,67 e 0,83**: o restante é ruído irreprodutível.

1.2. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O *baseline* é uma rede MLP básica treinada estritamente com **SGD padrão**, sem aceleradores adaptativos como Adam e sem termo de *momentum*. Nenhuma regularização explícita (L1, L2, *dropout*) foi aplicada nesta fase. Consideram-se **hiperparâmetros livres**, por integrarem a busca pelo “melhor modelo encontrado”, o número de camadas e neurônios, o formato das camadas, a função de ativação, a taxa de aprendizado, o tamanho de lote e o número de épocas.

O *early stopping* foi classificado como **regularização** [1] e, portanto, excluído do *baseline*: os pesos entregues são os da **última época**, com orçamento de épocas fixo e idêntico para todas as configurações. Uma versão preliminar restaurava os pesos da melhor época de validação; sua remoção obrigou a refazer toda a seleção de hiperparâmetros (Seção 4.1). Registram-se duas fronteiras discutíveis: a padronização dos dados, classificada como pré-processamento por não restringir a capacidade da rede nem alterar a função objetivo; e a escolha do número de épocas pela validação, que se distingue do *early stopping* por ser um orçamento fixo, igual para todas as configurações e sementes, e não um critério adaptativo aplicado a cada execução.

A busca empírica variou sistematicamente o número de camadas, os neurônios por camada, o formato das camadas, a função de ativação, a taxa de aprendizado, o tamanho de lote e o número de épocas, avaliando-se **estritamente pelo menor erro na validação** — o conjunto de teste não participou de nenhuma decisão de modelagem. Para evitar explosão combinatória, a busca foi conduzida **em três estágios**: em cada um testaram-se todas as combinações dos valores listados para aquele grupo de hiperparâmetros, mantendo-se os demais no melhor valor até então conhecido. A Tabela 2 detalha os valores explorados e a configuração final selecionada.

Tabela 2: Espaço amostrado e configuração final da MLP Baseline (Vanilla).

Hiperparâmetro	Valores Explorados	Escolhido (Vanilla)
Topologia das Camadas	1, 2 e 3 camadas; 4, 8, 16, 32, 64 e 128 neurônios (18 combinações)	$1 \rightarrow 64 \rightarrow 64 \rightarrow 64 \rightarrow 1$
Formato das Camadas	Uniforme, afunilado, expansivo, gargalo, 4 camadas (11 formatos)	Uniforme
Função de Ativação	ReLU, Tanh	ReLU
Otimizador	SGD padrão (momentum = 0,0, weight decay = 0,0)	SGD ($\eta = 0,01$)
Taxa de Aprendizado	0,01; 0,03; 0,1; 0,3	0,01
Tamanho do Lote	8, 16, 30	8
Número de Épocas	5.000; 10.000; 15.000; 20.000; 25.000; 30.000	10.000
Função de Custo	Erro Quadrático Médio	MSELoss
Crítério de Parada	Nenhum — orçamento fixo de épocas (ver Seção 1.2)	Últimos pesos
Semente Aleatória	Partição dos dados: 42 (fixa). Pesos iniciais: 0, 1 e 2 — as mesmas em todas as configurações	Média de 3 execuções

O modelo final possui **8.513 parâmetros**.

Por que três sementes por configuração. Os pesos iniciais da rede são sorteados aleatoriamente, e com apenas 30 amostras de treino esse sorteio pesa muito no resultado: o **mesmo baseline**, variando somente a semente, produz erro de validação entre 0,883 e 0,979 — uma variação de 11%, **maior que os efeitos que se deseja medir** (tipicamente de 1% a 5%). Fixar uma única semente tornaria a comparação pareada, mas não resolveria o problema: o efeito de um componente **interage** com o ponto de partida e pode inverter de sinal. A regularização L1 com $\lambda = 10^{-4}$, por exemplo, é 0,050 *pior* que o *baseline* na semente 0 e 0,051 *melhor* na semente 2 — com uma semente só, a conclusão registrada dependeria de qual tivesse sido escolhida. Por isso cada configuração é treinada três vezes, com as **mesmas** sementes (0, 1 e 2), reportando-se a média; o desvio entre elas fornece a escala de ruído usada nos testes t . Decisões de maior impacto, como a escolha da arquitetura, empregaram 6 a 8 sementes.

Estágio 1 — Topologia. As 18 combinações de largura e profundidade foram avaliadas com 3 sementes e as cinco melhores reconfirmadas com 8 sementes (Tabela 3). As três primeiras **empatam estatisticamente** (teste t de Welch contra a líder: $t = 1,17$ e $t = 1,18$), enquanto a 16×3 ($t = 2,62$) e a 32×3 ($t = 4,71$) são significativamente piores. Selecionou-se a 64×3 entre as empatadas por apresentar o **menor desvio entre sementes no teste de todas as arquiteturas avaliadas** ($\pm 0,013$), ou seja, maior reprodutibilidade — critério natural quando o desempenho empata. Registra-se que o menor erro de validação absoluto foi da 128×3 , e que a escolha repousa sobre empate estatístico somado a reprodutibilidade, não sobre superioridade medida.

Estágio 2 — Formato das camadas. O enunciado não exige largura uniforme, e tratá-la como valor único aplicado a todas as camadas é uma suposição que reduz a busca de N dimensões para 2. Ela foi testada explicitamente: 11 formatos alternativos, 6 sementes cada. O uniforme ($64-64-64$; validação $1,045 \pm 0,051$) **empata com o melhor formato encontrado**, o gargalo $64-16-64$ ($1,033 \pm 0,068$; $t = 0,35$), e os MSE de teste são idênticos até a quarta casa decimal (0,3767 contra 0,3764). Um achado contraria o senso comum: os **formatos afunilados foram sistematicamente piores** ($96-48-24$: 1,277; $64-32-16$: 1,329; $128-64-32-16$: 1,337), apesar de a intuição usual sugerir que camadas largas extraíam características e as seguintes as comprimam até a saída escalar.

Estágio 3 — Ativação, taxa, lote e épocas. Avaliaram-se 12 combinações com 4 sementes,

Tabela 3: Erros de treino e validação das arquiteturas candidatas a *baseline* (8 sementes, escala padronizada; MSE de teste incluído apenas para referência, não utilizado na seleção).

Arquitetura	Parâmetros	MSE treino	MSE validação	MSE teste
128×3	33.409	0,12	1,029 ± 0,087	0,377 ± 0,033
8×2	97	0,41	1,075 ± 0,070	0,404 ± 0,034
64×3	8.513	0,16	1,098 ± 0,141	0,377 ± 0,013
16×3	593	0,29	1,182 ± 0,141	0,384 ± 0,043
32×3	2.209	0,21	1,240 ± 0,092	0,407 ± 0,036

cada uma em 6 orçamentos de época, e os finalistas foram reconfirmados com 8 sementes. **As três primeiras posições foram todas ReLU**; a diferença para o melhor Tanh não é significativa ($t = 1,19$), mas o ReLU apresenta desvio entre sementes de 0,03–0,04 contra 0,11–0,14 do Tanh, sendo portanto cerca de **três vezes mais reprodutível**. Com três camadas, a saturação do Tanh atenua os gradientes retropropagados (gradiente evanescente), efeito que o ReLU não sofre por ter derivada unitária na região ativa.

O orçamento de épocas revelou-se hiperparâmetro de primeira ordem. Sem *early stopping*, quase toda combinação apresenta curva de validação em U — o erro melhora, atinge um mínimo e volta a subir (Tabela 4). Treinar além do mínimo produz apenas sobreajuste.

Tabela 4: Erro de validação por orçamento de épocas (rede 64×3, 4 sementes, escala padronizada). O mínimo de cada linha está em negrito.

Configuração	5.000	10.000	15.000	20.000	25.000	30.000
ReLU, $\eta = 0,01$, lote 8	1,076	0,933	0,951	0,997	1,037	1,047
Tanh, $\eta = 0,03$, lote 8	1,087	0,957	0,950	0,990	1,016	1,036
Tanh, $\eta = 0,01$, lote 16	1,456	1,267	1,158	1,128	1,083	0,991

Observa-se ainda uma **inversão instrutiva**: $\eta = 0,1$ era a melhor taxa enquanto havia *early stopping* — convergir rápido não tinha custo, pois os melhores pesos eram restaurados ao final. Sem esse mecanismo, taxa alta significa sobreajustar mais depressa, e $\eta = 0,1$ tornou-se a pior opção testada (validação de 1,26 a 1,50). Hiperparâmetros não são independentes do protocolo de treino.

2. Dinâmica de Treinamento e Convergência




Figura 1: Esquerda: evolução do MSE de treino e validação do *baseline* (escala padronizada, eixo logarítmico). A curva clara é o valor bruto por época e a linha escura é a média móvel de 101 épocas. Direita: ajuste obtido sobre os dados de teste.

Estabilidade do SGD. A alta variância visível nas curvas brutas da Figura 1 decorre da combinação




Figura 2: Comparação direta das curvas de validação: *baseline* contra os modelos com componentes adicionais.

de lote pequeno (8 amostras) com conjunto de treino diminuto (30 pontos): são apenas 4 atualizações por época, cada uma baseada em uma amostra ruidosa do gradiente. Sem momentum, não há acumulação de direção que suavize essas oscilações — é precisamente essa a função que o momentum desempenharia. A taxa de aprendizado mostrou-se o fator decisivo de estabilidade: em experimentos com $\eta = 0,3$ o treino **diverziu numericamente em todas as sementes**, e com $\eta = 0,1$ combinado a momentum $\geq 0,7$ em arquiteturas de três camadas observaram-se divergências (perda tendendo a NaN). A escolha de $\eta = 0,01$ mantém o treino em regime estável em toda a faixa de momentum testada.

Sobreajuste. O descolamento entre treino e validação é precoce e permanente. A perda de treino cai continuamente até $\approx 0,16$ (escala padronizada), enquanto a validação estabiliza em torno de 0,95 a partir da época 4.000 — uma razão de aproximadamente $6\times$. Na escala original, isso corresponde a $R^2 = 0,843$ no treino contra 0,288 no teste. A rede tem capacidade de sobra para memorizar o conjunto de treino, e o faz.

Aceleração com momentum. O momentum reduziu substancialmente o número de épocas até a convergência: de 7.939 no *baseline* para 2.884 com $\beta = 0,9$, uma redução de 64% (Tabela 5), confirmando seu papel como acelerador. Entretanto, **essa aceleração não se converteu em melhor generalização**: o erro final permaneceu estatisticamente indistinguível do *baseline*. Em um experimento anterior, com orçamento de épocas insuficiente, o momentum aparentava ser o melhor componente de todos (melhora de 11% no MSE de teste); ao estender o orçamento, a vantagem desapareceu por completo, revelando que ela era artefato de subtreino do *baseline*, e não mérito do componente.

3. Estudo de Ablação e Desempenho no Conjunto de Teste

Para isolar o efeito de cada componente, **a arquitetura foi mantida idêntica** à da Tabela 2 — mesmas camadas, mesmos neurônios, mesma ativação — variando-se exclusivamente o componente em estudo. A comparação é **pareada**: verificou-se empiricamente que *baseline* e ablações partem de **pesos iniciais idênticos** e, para L1, L2 e momentum, percorrem a **mesma sequência de minilotes**, sendo os resultados reprodutíveis bit a bit. A única exceção é o *dropout*, que consome números aleatórios ao sortear máscaras e portanto diverge da sequência a partir do primeiro sorteio — limitação inerente ao

método.

Cada configuração foi executada com **3 sementes** e os valores reportados são médias. Os valores de intensidade foram escolhidos de modo a **cercar o ótimo**: o melhor deve ter vizinhos piores dos dois lados, caso contrário faltaria explorar a região além dele.

Tabela 5: Estudo de ablação no conjunto de teste (240 pontos, 80% dos dados). Médias de 3 sementes, métricas na escala original de y . “Épocas até convergência” é a primeira época em que a validação suavizada entra a 2% do seu mínimo.

Modelo / Variação	MSE	RMSE	MAE	R^2	Épocas até conv.
Baseline Vanilla (SGD sem momentum)	0,3527	0,5938	0,4620	0,3158	7.939
<i>Regularização L1</i>					
$\lambda = 10^{-5}$	0,3559	0,5964	0,4644	0,3096	7.501
$\lambda = 10^{-4}$	0,3520	0,5930	0,4614	0,3171	7.267
$\lambda = 10^{-3}$	0,3844	0,6197	0,4900	0,2543	7.865
<i>Regularização L2 (weight decay)</i>					
$\lambda = 10^{-5}$	0,3553	0,5959	0,4642	0,3107	7.418
$\lambda = 10^{-4}$	0,3569	0,5972	0,4648	0,3078	7.346
$\lambda = 10^{-3}$	0,3590	0,5990	0,4673	0,3036	7.695
$\lambda = 10^{-2}$	0,4503	0,6710	0,5295	0,1265	7.281
<i>Dropout</i>					
$p = 0,1$	0,3943	0,6277	0,5006	0,2351	8.959
$p = 0,2$	0,4081	0,6386	0,5115	0,2083	7.655
$p = 0,3$	0,4386	0,6622	0,5347	0,1492	7.231
<i>Momentum</i>					
$\beta = 0,3$	0,3534	0,5944	0,4624	0,3144	6.369
$\beta = 0,5$	0,3571	0,5975	0,4650	0,3073	4.201
$\beta = 0,7$	0,3603	0,6001	0,4629	0,3010	5.087
$\beta = 0,9$	0,3588	0,5989	0,4638	0,3040	2.884
<i>Combinações dos melhores componentes</i>					
L1 10^{-4} + mom. 0,3	0,3645	0,6036	0,4690	0,2930	5.373
L2 10^{-5} + mom. 0,3	0,3556	0,5962	0,4638	0,3102	5.789
L1 10^{-4} + L2 10^{-5}	0,3573	0,5975	0,4662	0,3069	7.716
L1 + L2 + mom.	0,3648	0,6039	0,4693	0,2924	5.124

Nenhum componente melhorou o *baseline*. O melhor resultado da ablação é o L1 com $\lambda = 10^{-4}$, que reduz o MSE de teste em 0,0007 — dois décimos de por cento, indistinguível de ruído frente ao desvio entre sementes. As **combinações também não ajudaram**: a melhor delas (L2 + momentum) fica 0,0029 acima do *baseline*. E, diferentemente de experimentos preliminares, **as duas métricas concordam**: na validação — o critério de seleção — o *baseline* apresenta o menor erro de todos (0,9465), abaixo de qualquer configuração aditivada.

Por que nada funcionou. O orçamento de 10.000 épocas foi selecionado como o mínimo da curva de validação (Tabela 4), o que posiciona o *baseline* exatamente no ponto de equilíbrio entre subajuste e sobreajuste. A regularização existe para *deslocar* esse ponto; com o orçamento já ajustado ao mínimo, ela apenas restringe um modelo que já se encontra bem posicionado. Trata-se do mesmo mecanismo do *early stopping* reaparecendo sob outra forma: **ajustar o número de épocas pela validação captura o benefício que a regularização ofereceria**. Esta é a consequência prática da fronteira discutível declarada na Seção 1.2 — e sugere que, tivesse o orçamento sido fixado arbitrariamente em valor alto, L1 e L2 teriam apresentado ganho aparente que, na verdade, seria apenas compensação de um orçamento mal escolhido.

Comportamento por componente. L1 e L2 são neutros em intensidades fracas e destrutivos em intensidades fortes: L2 com $\lambda = 10^{-2}$ derruba o R^2 de 0,32 para 0,13, pois a penalização passa a dominar a função objetivo e a rede subajusta. Não se observou a diferença qualitativa esperada

entre L1 (indução à esparsidade) e L2 (atenuação de pesos grandes) — ambos degradam de forma semelhante conforme λ cresce, o que é coerente com o diagnóstico de que a limitação é o volume de dados, não a magnitude dos pesos. O *dropout* é claramente prejudicial e piora **monotonicamente** com a taxa ($0,394 \rightarrow 0,408 \rightarrow 0,439$): ele força a rede a não depender de neurônios individuais, o que exige redundância, e redundância exige dados; com 30 amostras, remove sinal em vez de ruído. Ressalte-se que sua curva de validação **ainda descia ao final do orçamento** (Figura 2), de modo que o orçamento fixo o penaliza.

O momentum acelera sem melhorar. É o resultado mais nítido da ablação: $\beta = 0,9$ atinge a convergência em **2.884 épocas contra 7.939 do *baseline***, uma redução de **64%**, chegando entretanto a um erro final estatisticamente indistinguível ($0,3588$ contra $0,3527$). A Figura 2 mostra o fenômeno graficamente: a curva do momentum descende mais rapidamente nas primeiras épocas, mas o *baseline* a alcança e termina ligeiramente abaixo. O momentum resolve o problema que o SGD puro possui — lentidão em vales estreitos da superfície de erro — sem alterar a qualidade da solução encontrada.




Figura 3: Evolução do treinamento para o *baseline* e configurações representativas de cada componente.




Figura 4: Esquerda: dispersão real *versus* predito no teste, com a reta $y = x$. Direita: resíduos ($y - \hat{y}$) em função do valor predito.

3.1. Estudo Complementar: Ablação em Rede Sobredimensionada

Como nenhum componente melhorou o *baseline*, investigou-se se isso se mantém quando a rede possui **mais capacidade excedente**. Repetiu-se a ablação numa rede 128×3 (33.409 parâmetros, $3,9 \times$ o *baseline*), mantendo **idênticos todos os demais hiperparâmetros** — ReLU, $\eta = 0,01$, lote 8, 10.000 épocas e as mesmas sementes — de modo que a capacidade seja a única variável alterada. A 128×3 é a base deste estudo, e as ablações não alteram sua arquitetura. Usou-se um conjunto reduzido, com dois valores por componente e sem combinações (Tabela 6).

Tabela 6: Ablação na rede 128×3 (3 sementes). MSE e R^2 no teste, em escala original; erro de validação na época final, em escala padronizada, com desvio entre sementes e teste t de Welch contra a base 128×3 ($|t| \gtrsim 2$ indica diferença significativa).

Configuração	MSE teste	R^2 teste	Val. final	t (val.)
<i>Baseline</i> 64×3 (referência)	0,3527	0,316	0,947	—
Base 128×3	0,3906	0,242	$1,002 \pm 0,007$	—
L1 $\lambda = 10^{-4}$	0,3933	0,237	$1,006 \pm 0,014$	+0,52
L1 $\lambda = 10^{-3}$	0,4185	0,188	$1,128 \pm 0,146$	+1,50
L2 $\lambda = 10^{-4}$	0,3852	0,253	$1,000 \pm 0,007$	-0,29
L2 $\lambda = 10^{-3}$	0,3871	0,249	$1,011 \pm 0,018$	+0,79
Dropout $p = 0,1$	0,3892	0,245	$0,988 \pm 0,015$	-1,42
Dropout $p = 0,2$	0,4014	0,221	$1,305 \pm 0,033$	+15,64
Momentum $\beta = 0,5$	0,3730	0,276	$0,988 \pm 0,020$	-1,12
Momentum $\beta = 0,9$	0,3702	0,282	$1,046 \pm 0,014$	+4,76




Figura 5: Curvas de validação na rede 128×3 : base contra componentes aditivados.

A capacidade excedente piora a generalização. Sem nenhum componente, a 128×3 tem MSE de teste 11% maior que o do *baseline* 64×3 (0,3906 contra 0,3527), confirmando o sobreajuste adicional.

A direção do efeito da regularização se inverte. Na 64×3 , todos os componentes empataram com o *baseline* ou o pioraram. Na 128×3 , dropout $p = 0,1$, momentum $\beta = 0,5$ e L2 $\lambda = 10^{-4}$ ficam à frente da base **simultaneamente na validação e no teste** — comportamento coerente com a teoria: havendo capacidade sobrando, a regularização passa a ter o que conter. Entretanto, **nenhuma dessas melhorias é estatisticamente significativa** ($|t| \leq 1,42$): com três sementes, trata-se de uma tendência na direção esperada, não de um ganho demonstrado.

O momentum $\beta = 0,9$ apresenta resultados contraditórios. É o melhor no teste (MSE 0,3702, -5%), mas significativamente pior na validação ($t = 4,76$). A Figura 5 explica a discrepância: ele atinge o patamar mínimo por volta da época 800 — contra cerca de 5.000 da base — e volta a subir ao final do treino, justamente na janela em que o erro de validação final é medido. Pelo critério de seleção adotado, ele não pode ser declarado superior.

Conclusão do estudo complementar. Mesmo a melhor variante da rede sobredimensionada (0,3702) é **pior que o *baseline* 64×3 sem componente algum** (0,3527). Regularizar uma rede grande demais não compensa a escolha adequada de capacidade: neste problema, dimensionar a rede corretamente foi mais eficaz do que qualquer técnica de regularização aplicada a uma rede superdimensionada.

4. Discussão e Lições Aprendidas

Sobreajuste no regime de poucos dados. Com 30 amostras de treino, o fator limitante não é a arquitetura, e sim o volume de dados. A evidência é direta: arquiteturas de 97 a 33.409 parâmetros — uma variação de $344\times$ — produziram MSE de teste entre 0,377 e 0,407, uma diferença de cerca de 1% da amplitude de y . Nenhuma escolha de topologia rompe esse teto.

Análise de resíduos. A Figura 4 revela **atenuação** acentuada: o ajuste linear de predito contra real tem inclinação 0,463, quando o ideal seria 1,0, e as previsões cobrem apenas **60% da amplitude real** ($[-1,17, 1,29]$ contra $[-1,49, 2,66]$). Os resíduos apresentam estrutura sistemática por faixa: $-0,242$ nos valores baixos de y , $+0,157$ nos médios e $+0,737$ nos altos. O modelo **subestima sistematicamente os extremos superiores**. Trata-se de regressão à média: sob ruído elevado ($\sigma \approx 0,42$) e poucos dados, prever próximo à média minimiza o erro quadrático esperado, ao custo de sacrificar as caudas. Esse padrão **persiste em todos os modelos regularizados** — nenhuma das técnicas de ablação o corrigiu, pois nenhuma ataca sua causa, que é a escassez de dados.

Perspectiva realista de desempenho. O R^2 de teste de 0,288 deve ser lido contra o teto estimado de 0,67–0,83 imposto pelo ruído dos dados. O modelo recupera, portanto, cerca de **40% do sinal aprendível**, e não 29% de um ideal de 100%. O restante não é falha do modelo: é ruído irreprodutível.

4.1. Trajetória do Desenvolvimento e Revisões

Três decisões foram revistas durante o trabalho, e os motivos são instrutivos.

O *early stopping* foi identificado como violação do enunciado. Versões iniciais restauravam os pesos da melhor época de validação. Como as escolhas de hiperparâmetros haviam sido feitas sob esse protocolo, removê-lo exigiu refazer toda a seleção — e ela de fato mudou: arquitetura de 32×3 para 64×3 , ativação de Tanh para ReLU, taxa de 0,1 para 0,01, lote de 16 para 8 e orçamento de 30.000 para 10.000 épocas. A configuração final é **significativamente melhor** que a anterior na validação ($t = 2,63$), de modo que a correção de conformidade trouxe também ganho de desempenho.

A largura uniforme era suposição não declarada. Detectada e testada explicitamente (Estágio 2), confirmou-se inofensiva — mas isso só é afirmável porque foi medido.

Diferenças aparentes desapareceram ao aumentar o número de sementes. Em três ocasiões uma configuração parecia superior com 3 sementes e perdia a vantagem com 6 ou 8. A arquitetura 16×3 , por exemplo, aparecia em segundo lugar (validação 1,037) e caiu para quarto (1,182) ao ser reavaliada. Por isso todas as decisões finais reportam desvio-padrão e teste t , e não apenas a média.

4.2. Limitações

- **Validação com 30 pontos é frágil** para seleção de modelos. As diferenças entre as arquiteturas do topo não são estatisticamente significativas, de modo que a escolha final repousa sobre empate somado a critério de reprodutibilidade. O remédio adequado seria **validação cruzada k -fold** sobre treino e validação, eliminando a dependência de um único corte; não foi realizada por custo computacional.
- **A busca foi por estágios, não conjunta.** Trata-se de otimização por coordenadas com uma

única passada, que não garante o ótimo global do espaço conjunto de hiperparâmetros.

- **O orçamento fixo de épocas penaliza componentes de convergência mais lenta**, o *dropout* em particular, cuja curva de validação ainda descia ao final do orçamento.
- **Métricas de execução única.** Os gráficos ilustrativos provêm de uma semente; as tabelas de ablação usam média de três e são mais confiáveis.

Referências

- [1] I. Goodfellow, Y. Bengio e A. Courville. *Deep Learning*. MIT Press, 2016. Capítulo 7.8, “Early Stopping as a Regularizer”.