# Projeto 2: Aprendizado Não Supervisionado

Quantização de Cores com SOM e GNG

Disciplina: Introdução às Redes Neurais Artificiais

**Autor:** Arthur Santos de Oliveira (RA: 156297)

**Repositório / Código Reprodutível:**

https://github.com/Arthur-so/introducao-a-redes-neurais

---

## 1. Configuração Experimental

**Ideia.** Cada pixel é uma amostra com três características (R, G, B) e cada neurônio é uma cor da paleta. Após o treino, cada pixel recebe a cor do seu neurônio vencedor (BMU), e a imagem passa a ter apenas $K$ cores.

**Imagens e pré-processamento.** Cinco fotos de $200 \times 200$ pixels (40.000 amostras cada): (1) lago com floresta, (2) crianças com cachorro, (3) cidade à noite, (4) pôr do sol na praia e (5) flores numa porta. O RGB foi normalizado para $[0, 1]$ e **todos os pixels** foram usados no treino.

**Redes.** SOM com grids $4 \times 4$, $8 \times 8$ e $16 \times 16$ e GNG com 16, 64 e 256 neurônios, ou seja, paletas de 16, 64 e 256 cores. São **30 simulações base** (5 imagens $\times$ 6 redes). O SOM usa a biblioteca MiniSom e a GNG foi implementada em Python. A Tabela 1 resume os hiperparâmetros.

Tabela 1: Hiperparâmetros das redes base.

| Item | Valor |
|---|---|
| GNG (valores mais utilizados) | $\eta_b = 10^{-2}$, $\eta_n = 10^{-4}$, $\beta = 0{,}005$, $\alpha = 0{,}5$, $\lambda = 50$, $a_{max} = 90$ |
| SOM | vizinhança gaussiana, $\sigma_0 = 2$, $\eta_0 = 0{,}1$ |
| Decaimento no SOM | padrão do MiniSom: $\eta(t) = \eta_0/(1 + 2t/T)$, e o mesmo para $\sigma$ |
| Treino | 5 passagens por todos os pixels, em ordem aleatória (igual para SOM e GNG) |
| Inicialização | SOM e GNG começam com as cores de pixels sorteados da imagem |
| Parada da GNG | insere neurônios até o número alvo; depois só adapta, até o fim das 5 passagens |
| Semente | 42 |

Os valores do SOM foram escolhidos com um teste nas imagens 1 e 4, com $\sigma_0 \in \{1, 2, 4\}$ e $\eta_0 \in \{0{,}1;\ 0{,}5\}$: $\sigma_0 = 2$ deu o melhor equilíbrio entre os dois erros, e as duas taxas ficaram próximas.

**Métricas:** foram usados o erro de quantização e o erro topológico.

- **Erro de quantização**: $EQ = \frac{1}{n} \sum_{i=1}^{n} \|x_i - w_{BMU(x_i)}\|$, a distância média entre cada pixel e a cor do seu BMU (RGB em $[0, 1]$). A distância de cada pixel, isoladamente, é o "erro do pixel" usado nos histogramas.
- **Erro topológico**: $ET = \frac{1}{n} \sum_{i=1}^{n} t(x_i)$, em que $t(x) = 0$ se o 1º e o 2º BMU de $x$ são vizinhos e $t(x) = 1$ caso contrário. Ou seja, o ET é a proporção de pixels cujos dois neurônios mais próximos não são vizinhos na rede. No SOM, vizinhos são células adjacentes no grid (incluindo as diagonais); na GNG, são neurônios ligados por uma aresta do grafo final.

## 2. Resultados das 30 Simulações

A Tabela 2 traz o EQ e o ET de todas as simulações base, e a Figura 1 mostra as 5 imagens quantizadas pelas 6 redes.

Tabela 2: Erro de quantização (EQ) e erro topológico (ET) das 30 simulações base. Menor é melhor.

| **Imagem** | **SOM 4×4** | **SOM 8×8** | **SOM 16×16** | **GNG 16** | **GNG 64** | **GNG 256** |
|---|---|---|---|---|---|---|
| *Erro de quantização (EQ)* | | | | | | |
| 1. Lago/floresta | 0,0175 | 0,0101 | 0,0062 | 0,0151 | 0,0113 | 0,0075 |
| 2. Crianças/cachorro | 0,0997 | 0,0499 | 0,0272 | 0,0748 | 0,0416 | 0,0272 |
| 3. Cidade à noite | 0,0664 | 0,0382 | 0,0242 | 0,0538 | 0,0372 | 0,0293 |
| 4. Pôr do sol | 0,0405 | 0,0210 | 0,0117 | 0,0338 | 0,0192 | 0,0124 |
| 5. Flores/porta | 0,0579 | 0,0349 | 0,0215 | 0,0501 | 0,0320 | 0,0242 |
| **Média** | **0,0564** | **0,0308** | **0,0182** | **0,0455** | **0,0283** | **0,0201** |
| *Erro topológico (ET)* | | | | | | |
| 1. Lago/floresta | 0,1588 | 0,0461 | 0,1752 | 0,0000 | 0,0002 | 0,0016 |
| 2. Crianças/cachorro | 0,0026 | 0,0242 | 0,0607 | 0,0011 | 0,0062 | 0,0044 |
| 3. Cidade à noite | 0,0547 | 0,0376 | 0,0807 | 0,0000 | 0,0035 | 0,0060 |
| 4. Pôr do sol | 0,0016 | 0,0249 | 0,0265 | 0,0008 | 0,0033 | 0,0027 |
| 5. Flores/porta | 0,0699 | 0,1116 | 0,0638 | 0,0001 | 0,0023 | 0,0051 |
| **Média** | **0,0575** | **0,0489** | **0,0814** | **0,0004** | **0,0031** | **0,0040** |

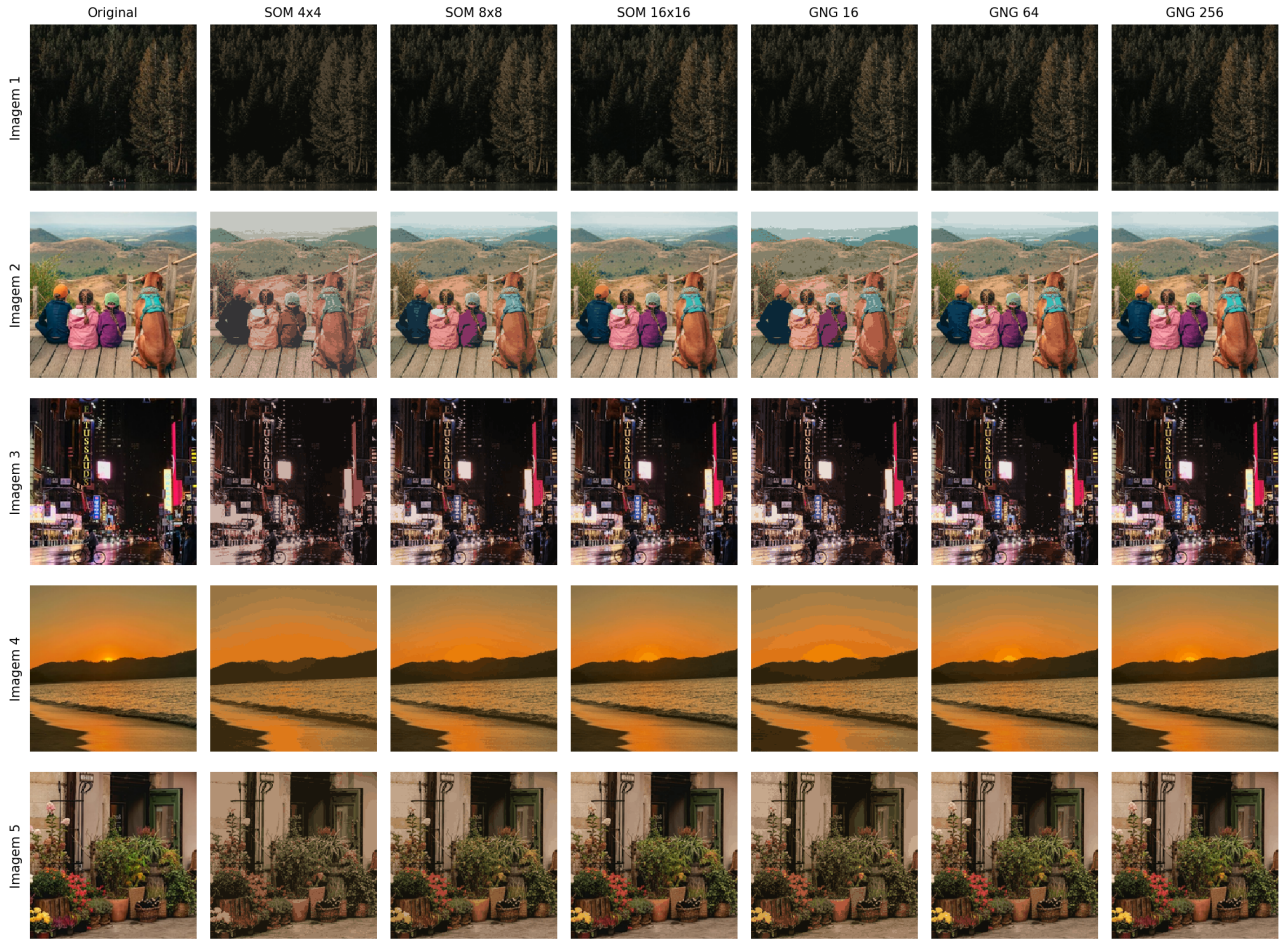



Figura 1: As 5 imagens originais (1ª coluna) e quantizadas pelas 6 redes base.

### 2.1. Número de cores

Em todas as imagens e nos dois modelos, **o EQ cai à medida que o número de cores aumenta**: a cada vez que $K$ é multiplicado por 4, o EQ médio cai entre 29% e 45%. Visualmente (Figura 1), com 16 cores todas as imagens continuam reconhecíveis, mas perdem detalhes de cor; com 64 cores as diferenças para o original ficam pequenas; com 256 cores as imagens ficam praticamente iguais ao

original.

### 2.2. Análise por imagem

- **Imagem 1 (lago/floresta).** Teve o **menor EQ** de todas (entre 0,0062 e 0,0175), porque é quase toda verde-escura: as cores ficam próximas umas das outras e poucas cores bastam para representá-la. As seis versões quantizadas são visualmente quase idênticas ao original. Em compensação, foi a imagem com o **maior ET do SOM** nos grids $4 \times 4$ (0,1588) e $16 \times 16$ (0,1752).
- **Imagem 2 (crianças/cachorro).** Teve o **maior EQ** (0,0997 no SOM $4 \times 4$), pois reúne muitas cores bem diferentes em áreas pequenas: casacos azul, rosa e roxo, bonés laranja e verde, peitoral azul-turquesa do cachorro. No SOM $4 \times 4$, o casaco azul fica cinza-escuro, o roxo fica marrom e o céu fica cinza. A GNG 16 mantém o casaco azul-marinho e o roxo. Com 64 cores, quase todas as cores voltam, e o peitoral do cachorro reaparece azul-turquesa na GNG 64.
- **Imagem 3 (cidade à noite).** Mistura um fundo muito escuro com letreiros luminosos. No SOM $4 \times 4$, o letreiro magenta fica rosa-claro e os letreiros azuis ficam claros e sem cor; a GNG 16 mantém o magenta e o azul. Com 64 cores ou mais, os letreiros ficam fiéis nos dois modelos.
- **Imagem 4 (pôr do sol).** O céu é um degradê suave de laranja, que com 16 cores vira **faixas** bem visíveis (*banding*); com 64 as faixas ficam discretas. O sol, uma área pequena e mais clara, não aparece no SOM $4 \times 4$ e só fica amarelo, como no original, no SOM $16 \times 16$ e na GNG 64 e 256.
- **Imagem 5 (flores/porta).** Foto com muita textura. No SOM $4 \times 4$, as flores vermelhas ficam salmão-acinzentado e as amarelas ficam quase brancas; a GNG 16 mantém as duas cores. Com 64 cores, as flores ficam fiéis nos dois modelos.

**Padrão comum:** com 16 cores, **o SOM perde as cores saturadas que ocupam áreas pequenas** (casacos, letreiros, flores) e as troca por tons acinzentados, enquanto a GNG tende a mantê-las. A Figura 2 mostra isso nas paletas da imagem 2: a do SOM $4 \times 4$ não tem nenhum azul nem roxo.




Figura 2: Imagem 2 com 16 cores: SOM $4 \times 4$ (esquerda) e GNG 16 (direita), com a paleta extraída (a cor de cada neurônio) abaixo de cada uma.

### 2.3. SOM vs. GNG

**Erro de quantização.** Com 16 cores, a **GNG teve EQ menor nas 5 imagens** (média 0,0455 contra 0,0564 do SOM). Com 64 cores, a GNG venceu em 4 das 5 imagens; a exceção foi a imagem 1. Com 256 cores, o **SOM** $16 \times 16$ **teve o menor EQ** em 4 imagens e empatou na imagem 2.

**Por quê.** No SOM, cada neurônio puxa também os seus vizinhos do grid, e o mapa inteiro se estica como uma malha sobre as cores. Com poucos neurônios, as cores saturadas de áreas pequenas

recebem poucos pixels e acabam sem um neurônio próprio. A GNG insere cada novo neurônio perto do neurônio com **maior erro acumulado**; pixels de cores mal representadas acumulam erro alto e, por isso, ganham neurônios. Com 256 cores, há neurônios suficientes no SOM para cobrir todas as regiões de cor; já a GNG 256 deixou neurônios sem nenhum pixel (Seção 4), o que reduz o número de cores realmente usadas.

**Erro topológico.** A GNG teve ET praticamente nulo (no máximo 0,0062); o SOM ficou entre 0,0016 e 0,1752. Esses números **não devem ser comparados diretamente**. A cada pixel de treino, a GNG cria (ou renova) uma aresta entre os dois neurônios mais próximos desse pixel. Ou seja, a própria regra de treino liga exatamente os pares de neurônios que o ET verifica, e um ET baixo é esperado. No SOM, as vizinhanças são fixadas pelo grid antes do treino, e o ET mostra o quanto as cores da imagem se acomodam a essa malha 2D. O pior caso do SOM foi a imagem 1: com cores muito concentradas, é mais difícil estender o grid sobre elas sem dobras.

## 3. Distribuição dos Erros

A Figura 3 mostra o histograma do erro de cada pixel, para as 5 imagens.

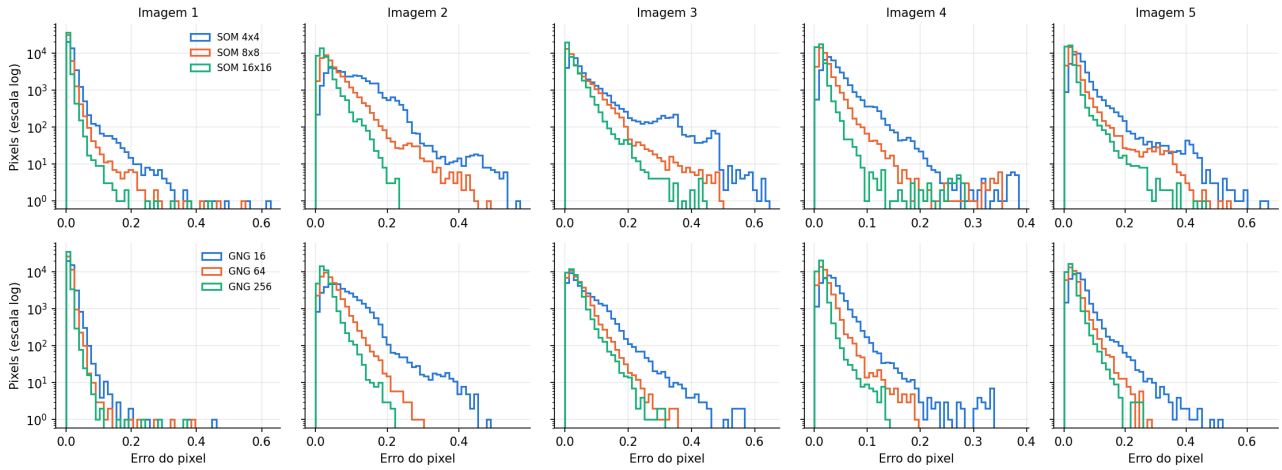



Figura 3: Histograma do erro por pixel (distância ao BMU) para cada imagem. Linha de cima: SOM; linha de baixo: GNG. O eixo vertical está em escala log.

- **Formato.** Em todas as imagens, a maioria dos pixels tem erro pequeno, mas há uma **cauda longa**: poucos pixels com erro bem maior que a média. Esses pixels são os de cores raras, que não ganharam um neurônio próprio.
- **Número de cores.** Mais neurônios deslocam a distribuição para a esquerda e encurtam a cauda: com 256 cores, quase não há pixels com erro alto.
- **SOM vs. GNG.** Com 16 cores, a cauda do SOM vai até erros maiores que a da GNG em todas as imagens. Nas imagens 2 e 3, o SOM $4 \times 4$ forma até um segundo "morro" de pixels com erro alto, que provavelmente corresponde aos casacos e letreiros saturados que mudaram de cor na Figura 1.
- **Imagem 1.** Tem a distribuição mais concentrada perto de zero, de acordo com o seu EQ, o menor de todos.

**Exemplo de cor rara.** Na imagem 1, uma pessoa num barco é o único detalhe avermelhado, numa imagem quase toda verde-escura. A Tabela 3 acompanha o pixel central dessa pessoa, $(185, 100)$, cuja cor é RGB $(129, 90, 81)$, e a Figura 4 mostra a região ampliada.

**A cor avermelhada some em todas as redes.** O pixel sempre recebe um marrom ou bege, com erro muitas vezes maior que o EQ da imagem (no SOM $4 \times 4$, 0,2482 contra 0,0175). Com mais

Tabela 3: Pixel de cor rara da imagem 1, cor original RGB $(129, 90, 81)$: cor recebida, erro do pixel e número de pixels da imagem que têm o mesmo BMU.

| Rede | Cor recebida (RGB) | Erro do pixel | EQ da imagem | Pixels no mesmo BMU |
|---|---|---|---|---|
| SOM 4×4 | (78, 68, 51) | 0,2482 | 0,0175 | 2312 |
| SOM 8×8 | (95, 81, 59) | 0,1609 | 0,0101 | 669 |
| SOM 16×16 | (109, 94, 74) | 0,0840 | 0,0062 | 163 |
| GNG 16 | (109, 92, 71) | 0,0882 | 0,0151 | 288 |
| GNG 64 | (118, 100, 81) | 0,0601 | 0,0113 | 96 |
| GNG 256 | (123, 105, 86) | 0,0666 | 0,0075 | 60 |

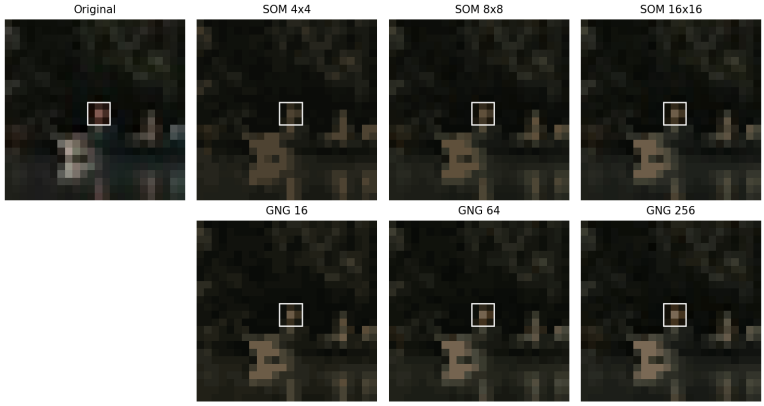



Figura 4: Região de $24 \times 24$ pixels em volta do pixel de cor rara (quadrado branco), ampliada.

neurônios, a cor recebida se aproxima da original e o BMU passa a ser compartilhado com menos pixels (de 2312 para 60), mas nenhuma rede criou um neurônio avermelhado. **Por quê:** o detalhe ocupa poucos pixels entre 40.000, e os neurônios se deslocam para onde há muitas amostras.

## 4. Uso dos Neurônios (Hit Maps)

O *hit map* mostra **quantos pixels cada neurônio captura**, isto é, para quantos pixels ele é o BMU. A Figura 5 mostra os *hit maps* da imagem 2, a mais colorida. Como ler:

- **SOM (linha de cima):** cada célula é um neurônio, na sua posição no grid, pintada com a cor do neurônio; o número é a quantidade de pixels que ele captura.
- **GNG (linha de baixo):** a GNG não tem grid, então cada barra é um neurônio, pintada com a sua cor. As barras estão ordenadas do neurônio mais usado para o menos usado, e a altura (em escala log) é o número de pixels.

**O que a figura mostra:**

- **Organização do SOM.** Células vizinhas têm cores parecidas: no grid $4 \times 4$, os tons claros do céu ficam no canto superior esquerdo, os tons avermelhados (cachorro, casaco rosa) à direita e os escuros no canto inferior direito. A cor muda aos poucos pelo grid, também no $8 \times 8$ e no $16 \times 16$. Isso é a preservação topológica, e combina com o ET baixo do SOM nessa imagem (0,0026 no $4 \times 4$).
- **Cores ausentes no SOM $4 \times 4$.** Nenhuma das 16 células é azul ou roxa, o que explica por que os casacos mudaram de cor na Figura 1. Na GNG 16, há uma barra azul-marinho e uma roxa (a menor de todas): a GNG reservou neurônios para essas cores, embora sejam pouco frequentes.
- **Distribuição do uso.** No SOM $4 \times 4$, o neurônio mais usado (cinza-claro, céu) captura 5117 pixels, 12,8% da imagem. Na GNG 16, o uso fica mais equilibrado, e o neurônio roxo é o menos

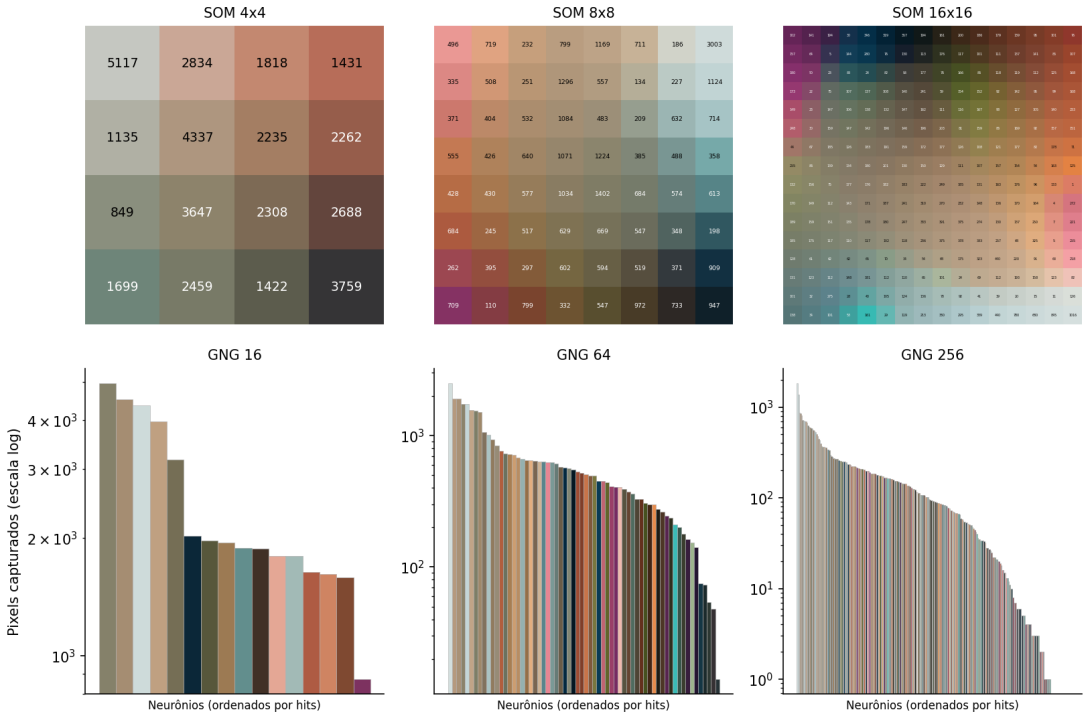



Figura 5: *Hit maps* da imagem 2. SOM: células do grid com a cor do neurônio e o número de pixels capturados. GNG: uma barra por neurônio, ordenadas do mais usado ao menos usado (escala log).

usado. Na GNG 256, o uso cai de forma contínua da esquerda para a direita, e o espaço vazio à direita das barras corresponde a **neurônios que não capturam nenhum pixel**.

A Tabela 4 resume o uso dos neurônios nas 5 imagens.

Tabela 4: Porcentagem dos pixels capturada pelo neurônio mais usado de cada rede e número de neurônios da GNG 256 sem nenhum pixel. Nas demais redes, todos os neurônios capturam ao menos um pixel.

| | % dos pixels no neurônio mais usado | | | | | | Sem pixels |
|---|---|---|---|---|---|---|---|
| **Imagem** | SOM 4×4 | SOM 8×8 | SOM 16×16 | GNG 16 | GNG 64 | GNG 256 | GNG 256 |
| 1. Lago/floresta | 24,4 | 7,7 | 3,4 | 17,3 | 12,1 | 4,9 | 52 |
| 2. Crianças/cachorro | 12,8 | 7,5 | 2,5 | 12,4 | 6,3 | 4,6 | 17 |
| 3. Cidade à noite | 29,4 | 9,1 | 2,9 | 21,9 | 19,3 | 12,6 | 46 |
| 4. Pôr do sol | 16,8 | 3,4 | 0,9 | 12,3 | 5,8 | 3,1 | 29 |
| 5. Flores/porta | 16,9 | 9,0 | 2,5 | 12,7 | 9,2 | 6,9 | 27 |

- **Imagens escuras concentram pixels num só neurônio.** Nas imagens 1 e 3, o neurônio mais usado do SOM $4 \times 4$ (uma cor quase preta) captura 24,4% e 29,4% dos pixels: o fundo escuro ocupa boa parte dessas imagens.
- **Com 256 cores, a GNG concentra mais pixels no neurônio mais usado que o SOM**, em todas as imagens (na imagem 3, 12,6% contra 2,9%); com 64 cores, isso ocorre em 4 das 5 imagens. Uma explicação provável é que a GNG insere neurônios onde o erro acumulado é maior, e uma região grande e uniforme, como o céu noturno, acumula pouco erro e pode ficar com um único neurônio.
- **Neurônios sem uso na GNG 256.** Em todas as imagens, entre 17 e 52 neurônios da GNG 256 não capturam nenhum pixel, enquanto o SOM usa todos os neurônios. Uma explicação provável é que cada neurônio novo da GNG nasce no ponto médio entre dois neurônios, e esse

ponto pode cair numa região de cor sem pixels. Isso ajuda a explicar por que, com 256 cores, o SOM teve EQ menor.

## 5. Variações: Vizinhança e Taxas

As variações foram rodadas nas imagens 1 e 4, mudando um parâmetro por vez em relação à configuração base (Tabela 5). Na vizinhança **bubble**, todos os neurônios a menos de $\sigma$ do vencedor no grid recebem o mesmo ajuste e os demais nenhum. No MiniSom, essa região é um quadrado em volta do vencedor.

Tabela 5: Variações nas imagens 1 e 4 (EQ e ET). A linha "base" repete a Tabela 2.

| | | **SOM 4×4** | | **SOM 8×8** | | **SOM 16×16** | |
|---|---|---|---|---|---|---|---|
| **Img.** | **Variação** | EQ | ET | EQ | ET | EQ | ET |
| 1 | base (gaussiana, $\sigma_0 = 2$, $\eta_0 = 0{,}1$) | 0,0175 | 0,1588 | 0,0101 | 0,0461 | 0,0062 | 0,1752 |
| 1 | bubble | 0,0152 | 0,0231 | 0,0091 | 0,3323 | 0,0057 | 0,3287 |
| 1 | $\sigma_0 = 1$ | 0,0152 | 0,1210 | 0,0091 | 0,2199 | 0,0058 | 0,2725 |
| 1 | $\sigma_0 = 4$ | 0,0289 | 0,0449 | 0,0123 | 0,2179 | 0,0076 | 0,1196 |
| 1 | $\eta_0 = 0{,}01$ | 0,0179 | 0,0859 | 0,0102 | 0,1674 | 0,0065 | 0,1500 |
| 1 | $\eta_0 = 0{,}5$ | 0,0192 | 0,0921 | 0,0103 | 0,2581 | 0,0064 | 0,0853 |
| 4 | base (gaussiana, $\sigma_0 = 2$, $\eta_0 = 0{,}1$) | 0,0405 | 0,0016 | 0,0210 | 0,0249 | 0,0117 | 0,0265 |
| 4 | bubble | 0,0338 | 0,1605 | 0,0185 | 0,1516 | 0,0104 | 0,1658 |
| 4 | $\sigma_0 = 1$ | 0,0343 | 0,0431 | 0,0182 | 0,0767 | 0,0104 | 0,1684 |
| 4 | $\sigma_0 = 4$ | 0,0818 | 0,0208 | 0,0274 | 0,0190 | 0,0145 | 0,0267 |
| 4 | $\eta_0 = 0{,}01$ | 0,0420 | 0,0618 | 0,0210 | 0,0278 | 0,0124 | 0,0750 |
| 4 | $\eta_0 = 0{,}5$ | 0,0428 | 0,0054 | 0,0212 | 0,0381 | 0,0117 | 0,0416 |
| | | **GNG 16** | | **GNG 64** | | **GNG 256** | |
| 1 | base | 0,0151 | 0,0000 | 0,0113 | 0,0002 | 0,0075 | 0,0016 |
| 1 | $\eta_b = 0{,}005$ | 0,0149 | 0,0000 | 0,0111 | 0,0001 | 0,0084 | 0,0012 |
| 1 | $\eta_b = 0{,}05$ | 0,0155 | 0,0006 | 0,0099 | 0,0006 | 0,0064 | 0,0044 |
| 1 | $\eta_n = 0{,}001$ | 0,0149 | 0,0000 | 0,0104 | 0,0001 | 0,0075 | 0,0012 |
| 1 | $\lambda = 25$ | 0,0150 | 0,0001 | 0,0100 | 0,0007 | 0,0078 | 0,0012 |
| 1 | $\lambda = 100$ | 0,0153 | 0,0005 | 0,0118 | 0,0021 | 0,0074 | 0,0019 |
| 4 | base | 0,0338 | 0,0008 | 0,0192 | 0,0033 | 0,0124 | 0,0027 |
| 4 | $\eta_b = 0{,}005$ | 0,0336 | 0,0000 | 0,0198 | 0,0014 | 0,0134 | 0,0022 |
| 4 | $\eta_b = 0{,}05$ | 0,0342 | 0,0000 | 0,0185 | 0,0023 | 0,0115 | 0,0058 |
| 4 | $\eta_n = 0{,}001$ | 0,0353 | 0,0001 | 0,0193 | 0,0014 | 0,0119 | 0,0027 |
| 4 | $\lambda = 25$ | 0,0338 | 0,0008 | 0,0188 | 0,0017 | 0,0121 | 0,0041 |
| 4 | $\lambda = 100$ | 0,0337 | 0,0006 | 0,0189 | 0,0014 | 0,0125 | 0,0029 |

**Gaussiana vs. bubble.** A bubble teve **EQ menor em todos os casos**, mas **ET muito maior** em 5 dos 6 (na imagem 4, de 0,0016 para 0,1605 no grid $4 \times 4$); a exceção foi o grid $4 \times 4$ da imagem 1. **Por quê:** na bubble, quando $\sigma$ cai abaixo de 1, só o vencedor aprende, e o mapa para de se organizar mais cedo. Cada neurônio fica livre para se ajustar à sua cor (EQ menor), mas neurônios vizinhos no grid deixam de ter cores parecidas (ET maior). Na gaussiana, os vizinhos continuam recebendo um ajuste menor até o fim, o que mantém o mapa organizado.

**Raio inicial $\sigma_0$.** $\sigma_0 = 1$ (menos cooperação entre vizinhos) se comporta como a bubble: EQ menor em todos os casos e ET maior em 5 dos 6. $\sigma_0 = 4$ (mais cooperação) aumentou o EQ em todos os casos (na imagem 4, grid $4 \times 4$, de 0,0405 para 0,0818), mas não reduziu o ET de forma consistente. **Há uma troca entre EQ e ET**: menos cooperação dá cores mais precisas e um mapa menos organizado; $\sigma_0 = 2$ ficou no meio-termo.

**Taxa de aprendizado do SOM ($\eta_0$).** A taxa base, 0,1, teve EQ igual ou menor que 0,01 e 0,5 em todos os casos, mas as diferenças são pequenas (a maior foi no grid $4 \times 4$ da imagem 4: 0,0405 contra 0,0428 com $\eta_0 = 0{,}5$). O ET do SOM mudou bastante entre as taxas, sem uma direção clara.

**Taxas e $\lambda$ da GNG.** Com $\eta_b = 0{,}05$ (o vencedor se move mais), o EQ caiu nas redes de 64 e 256 neurônios (imagem 1, GNG 256: de 0,0075 para 0,0064), e o ET aumentou em 3 desses 4 casos. Com $\eta_b = 0{,}005$, o EQ da GNG 256 piorou nas duas imagens. A taxa dos vizinhos $\eta_n = 0{,}001$ e as mudanças

de $\lambda$ alteraram pouco o EQ e sem direção consistente: com 5 passagens pelos dados, a rede atinge o número alvo de neurônios em qualquer caso e depois só se adapta. **Os valores base da GNG funcionaram bem** e não precisaram de ajuste.

## 6. Discussão e Conclusões

- **SOM (rede fixa) vs. GNG (topologia adaptativa).** Com poucas cores, a GNG representa melhor as imagens, porque coloca neurônios onde o erro é grande e mantém as cores saturadas de áreas pequenas, que o SOM $4 \times 4$ perde. Com 256 cores, o SOM $16 \times 16$ fica um pouco à frente, em parte porque alguns neurônios da GNG 256 ficam sem uso. O SOM, por sua vez, organiza as cores no grid de forma que neurônios vizinhos tenham cores parecidas, como se vê nos *hit maps*.

- **Número de cores.** 16 cores bastam para reconhecer as imagens, mas criam faixas nos degradês (imagem 4) e trocam as cores de detalhes (imagens 2, 3 e 5). Com 64 cores o resultado já é bom, e com 256 fica praticamente igual ao original.

- **Cores raras desaparecem.** Detalhes de cor muito pouco frequentes, como a pessoa avermelhada da imagem 1, não ganham um neurônio próprio em nenhuma rede.

- **Vizinhança e taxas.** A vizinhança gaussiana preserva melhor a topologia que a bubble, ao custo de um EQ um pouco maior. As taxas de aprendizado tiveram efeito pequeno no EQ dentro dos valores testados.

- **Revisões durante o desenvolvimento.** (i) A GNG começava com 2 neurônios de cores sorteadas em todo o cubo RGB; isso deixava neurônios longe dos dados e quase sem pixels, então ela passou a começar com as cores de 2 pixels sorteados, como o SOM. (ii) Parar a GNG ao atingir o número alvo faria a GNG de 16 neurônios ver só cerca de 750 pixels; por isso ela continua se adaptando até completar as 5 passagens.

- **Limitações.** Cada configuração foi treinada com uma única semente, e o ET do SOM variou bastante entre configurações próximas, então pequenas diferenças de ET não devem ser interpretadas. O ET da GNG não é comparável ao do SOM, como explicado na Seção 2.3.