Projeto 2: Aprendizado Não Supervisionado

Quantização de Cores com SOM e GNG

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Arthur Santos de Oliveira (RA: 156297)

Repositório / Código Reprodutível:

https://github.com/Arthur-so/introducao-a-redes-neurais

---

1. Configuração Experimental

Ideia. Cada pixel é uma amostra com três características (R, G, B) e cada neurônio é uma cor da paleta. Após o treino, cada pixel recebe a cor do seu neurônio vencedor (BMU), e a imagem passa a ter apenas K cores.

Imagens e pré-processamento. Cinco fotos de 200×200 pixels (40.000 amostras cada): (1) lago com floresta, (2) crianças com cachorro, (3) cidade à noite, (4) pôr do sol na praia e (5) flores numa porta. O RGB foi normalizado para $[0, 1]$ e **todos os pixels** foram usados no treino.

Redes. SOM com grids 4×4, 8×8 e 16×16 e GNG com 16, 64 e 256 neurônios, ou seja, paletas de 16, 64 e 256 cores. São **30 simulações base** (5 imagens $\times$ 6 redes). O SOM usa a biblioteca MiniSom e a GNG foi implementada em Python. A Tabela 1 resume os hiperparâmetros.

Tabela 1: Hiperparâmetros das redes base.

Item	Valor
GNG (valores mais utilizados)	$\eta_b = 10^{-2}$, $\eta_n = 10^{-4}$, $\beta = 0{,}005$, $\alpha = 0{,}5$, $\lambda = 50$, $a_{max} = 90$
SOM	vizinhança gaussiana, $\sigma_0 = 2$, $\eta_0 = 0{,}1$
Decaimento no SOM	padrão do MiniSom: $\eta(t) = \eta_0/(1 + 2t/T)$, e o mesmo para σ
Treino	5 passagens por todos os pixels, em ordem aleatória (igual para SOM e GNG)
Inicialização	SOM e GNG começam com as cores de pixels sorteados da imagem
Parada da GNG	insere neurônios até o número alvo; depois só adapta, até o fim das 5 passagens
Semente	42

Os valores do SOM foram escolhidos com um teste nas imagens 1 e 4, com $\sigma_0 \in \{1, 2, 4\}$ e $\eta_0 \in \{0{,}1;\ 0{,}5\}$: $\sigma_0 = 2$ deu o melhor equilíbrio entre os dois erros, e as duas taxas ficaram próximas.

Métricas: foram usados o erro de quantização e o erro topológico.

- **Erro de quantização**: $EQ = \frac{1}{n} \sum_{i=1}^{n} \|x_i - w_{BMU(x_i)}\|$, a distância média entre cada pixel e a cor do seu BMU (RGB em $[0, 1]$). A distância de cada pixel, isoladamente, é o "erro do pixel" usado nos histogramas.
- **Erro topológico**: $ET = \frac{1}{n} \sum_{i=1}^{n} t(x_i)$, em que $t(x) = 0$ se o 1º e o 2º BMU de x são vizinhos e $t(x) = 1$ caso contrário. Ou seja, o ET é a proporção de pixels cujos dois neurônios mais próximos não são vizinhos na rede. No SOM, vizinhos são células adjacentes no grid (incluindo as diagonais); na GNG, são neurônios ligados por uma aresta do grafo final.

2. Resultados das 30 Simulações

A Tabela 2 traz o EQ e o ET de todas as simulações base, e a Figura 1 mostra as 5 imagens quantizadas pelas 6 redes.

Tabela 2: Erro de quantização (EQ) e erro topológico (ET) das 30 simulações base. Menor é melhor.

Imagem	**SOM 4×4**	**SOM 8×8**	**SOM 16×16**	**GNG 16**	**GNG 64**	**GNG 256**
Erro de quantização (EQ)						
1. Lago/floresta	0,0175	0,0101	0,0062	0,0151	0,0113	0,0075
2. Crianças/cachorro	0,0997	0,0499	0,0272	0,0748	0,0416	0,0272
3. Cidade à noite	0,0664	0,0382	0,0242	0,0538	0,0372	0,0293
4. Pôr do sol	0,0405	0,0210	0,0117	0,0338	0,0192	0,0124
5. Flores/porta	0,0579	0,0349	0,0215	0,0501	0,0320	0,0242
Média	**0,0564**	**0,0308**	**0,0182**	**0,0455**	**0,0283**	**0,0201**
Erro topológico (ET)						
1. Lago/floresta	0,1588	0,0461	0,1752	0,0000	0,0002	0,0016
2. Crianças/cachorro	0,0026	0,0242	0,0607	0,0011	0,0062	0,0044
3. Cidade à noite	0,0547	0,0376	0,0807	0,0000	0,0035	0,0060
4. Pôr do sol	0,0016	0,0249	0,0265	0,0008	0,0033	0,0027
5. Flores/porta	0,0699	0,1116	0,0638	0,0001	0,0023	0,0051
Média	**0,0575**	**0,0489**	**0,0814**	**0,0004**	**0,0031**	**0,0040**

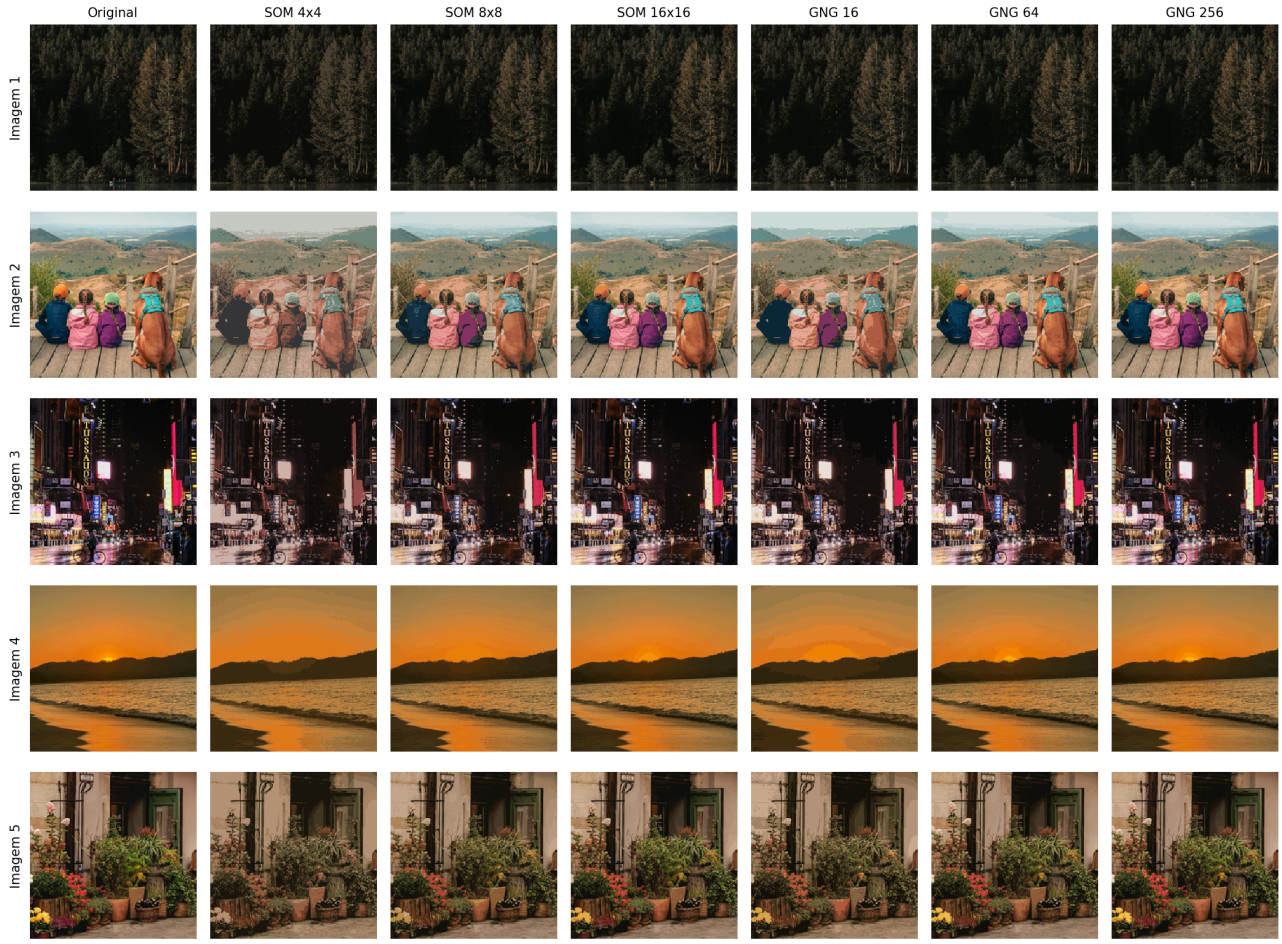


Figura 1: As 5 imagens originais (1ª coluna) e quantizadas pelas 6 redes base.

2.1. Número de cores

Em todas as imagens e nos dois modelos, **o EQ cai à medida que o número de cores aumenta**: a cada vez que K é multiplicado por 4, o EQ médio cai entre 29% e 45%. Visualmente (Figura 1), com 16 cores todas as imagens continuam reconhecíveis, mas perdem detalhes de cor; com 64 cores as diferenças para o original ficam pequenas; com 256 cores as imagens ficam praticamente iguais ao

original.

2.2. Análise por imagem

- **Imagem 1 (lago/floresta).** Teve o **menor EQ** de todas (entre 0,0062 e 0,0175), porque é quase toda verde-escura: as cores ficam próximas umas das outras e poucas cores bastam para representá-la. As seis versões quantizadas são visualmente quase idênticas ao original. Em compensação, foi a imagem com o **maior ET do SOM** nos grids 4×4 (0,1588) e 16×16 (0,1752).
- **Imagem 2 (crianças/cachorro).** Teve o **maior EQ** (0,0997 no SOM 4×4), pois reúne muitas cores bem diferentes em áreas pequenas: casacos azul, rosa e roxo, bonés laranja e verde, peitoral azul-turquesa do cachorro. No SOM 4×4, o casaco azul fica cinza-escuro, o roxo fica marrom e o céu fica cinza. A GNG 16 mantém o casaco azul-marinho e o roxo. Com 64 cores, quase todas as cores voltam, e o peitoral do cachorro reaparece azul-turquesa na GNG 64.
- **Imagem 3 (cidade à noite).** Mistura um fundo muito escuro com letreiros luminosos. No SOM 4×4, o letreiro magenta fica rosa-claro e os letreiros azuis ficam claros e sem cor; a GNG 16 mantém o magenta e o azul. Com 64 cores ou mais, os letreiros ficam fiéis nos dois modelos.
- **Imagem 4 (pôr do sol).** O céu é um degradê suave de laranja, que com 16 cores vira **faixas** bem visíveis (*banding*); com 64 as faixas ficam discretas. O sol, uma área pequena e mais clara, não aparece no SOM 4×4 e só fica amarelo, como no original, no SOM 16×16 e na GNG 64 e 256.
- **Imagem 5 (flores/porta).** Foto com muita textura. No SOM 4×4, as flores vermelhas ficam salmão-acinzentado e as amarelas ficam quase brancas; a GNG 16 mantém as duas cores. Com 64 cores, as flores ficam fiéis nos dois modelos.

Padrão comum: com 16 cores, **o SOM perde as cores saturadas que ocupam áreas pequenas** (casacos, letreiros, flores) e as troca por tons acinzentados, enquanto a GNG tende a mantê-las. A Figura 2 mostra isso nas paletas da imagem 2: a do SOM 4×4 não tem nenhum azul nem roxo.



Figura 2: Imagem 2 com 16 cores: SOM 4×4 (esquerda) e GNG 16 (direita), com a paleta extraída (a cor de cada neurônio) abaixo de cada uma.

2.3. SOM vs. GNG

Erro de quantização. Com 16 cores, a **GNG teve EQ menor nas 5 imagens** (média 0,0455 contra 0,0564 do SOM). Com 64 cores, a GNG venceu em 4 das 5 imagens; a exceção foi a imagem 1. Com 256 cores, o **SOM** 16×16 **teve o menor EQ** em 4 imagens e empatou na imagem 2.

Por quê. No SOM, cada neurônio puxa também os seus vizinhos do grid, e o mapa inteiro se estica como uma malha sobre as cores. Com poucos neurônios, as cores saturadas de áreas pequenas

recebem poucos pixels e acabam sem um neurônio próprio. A GNG insere cada novo neurônio perto do neurônio com **maior erro acumulado**; pixels de cores mal representadas acumulam erro alto e, por isso, ganham neurônios. Com 256 cores, há neurônios suficientes no SOM para cobrir todas as regiões de cor; já a GNG 256 deixou neurônios sem nenhum pixel (Seção 4), o que reduz o número de cores realmente usadas.

Erro topológico. A GNG teve ET praticamente nulo (no máximo 0,0062); o SOM ficou entre 0,0016 e 0,1752. Esses números **não devem ser comparados diretamente**. A cada pixel de treino, a GNG cria (ou renova) uma aresta entre os dois neurônios mais próximos desse pixel. Ou seja, a própria regra de treino liga exatamente os pares de neurônios que o ET verifica, e um ET baixo é esperado. No SOM, as vizinhanças são fixadas pelo grid antes do treino, e o ET mostra o quanto as cores da imagem se acomodam a essa malha 2D. O pior caso do SOM foi a imagem 1: com cores muito concentradas, é mais difícil estender o grid sobre elas sem dobras.

3. Distribuição dos Erros

A Figura 3 mostra o histograma do erro de cada pixel, para as 5 imagens.

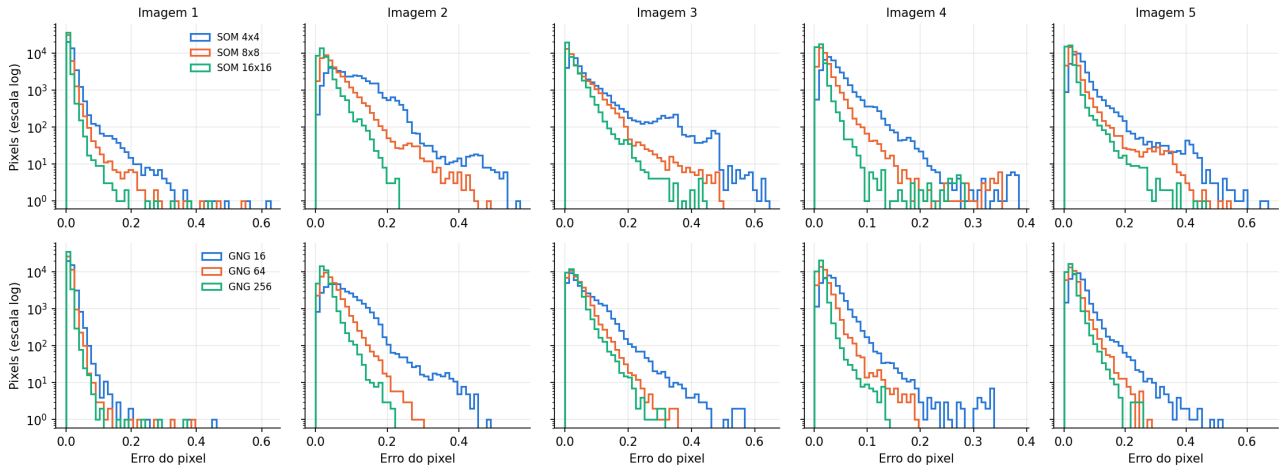


Figura 3: Histograma do erro por pixel (distância ao BMU) para cada imagem. Linha de cima: SOM; linha de baixo: GNG. O eixo vertical está em escala log.

- **Formato.** Em todas as imagens, a maioria dos pixels tem erro pequeno, mas há uma **cauda longa**: poucos pixels com erro bem maior que a média. Esses pixels são os de cores raras, que não ganharam um neurônio próprio.
- **Número de cores.** Mais neurônios deslocam a distribuição para a esquerda e encurtam a cauda: com 256 cores, quase não há pixels com erro alto.
- **SOM vs. GNG.** Com 16 cores, a cauda do SOM vai até erros maiores que a da GNG em todas as imagens. Nas imagens 2 e 3, o SOM 4×4 forma até um segundo "morro" de pixels com erro alto, que provavelmente corresponde aos casacos e letreiros saturados que mudaram de cor na Figura 1.
- **Imagem 1.** Tem a distribuição mais concentrada perto de zero, de acordo com o seu EQ, o menor de todos.

Exemplo de cor rara. Na imagem 1, uma pessoa num barco é o único detalhe avermelhado, numa imagem quase toda verde-escura. A Tabela 3 acompanha o pixel central dessa pessoa, $(185, 100)$, cuja cor é RGB $(129, 90, 81)$, e a Figura 4 mostra a região ampliada.

A cor avermelhada some em todas as redes. O pixel sempre recebe um marrom ou bege, com erro muitas vezes maior que o EQ da imagem (no SOM 4×4, 0,2482 contra 0,0175). Com mais

Tabela 3: Pixel de cor rara da imagem 1, cor original RGB $(129, 90, 81)$: cor recebida, erro do pixel e número de pixels da imagem que têm o mesmo BMU.

Rede	Cor recebida (RGB)	Erro do pixel	EQ da imagem	Pixels no mesmo BMU
SOM 4×4	(78, 68, 51)	0,2482	0,0175	2312
SOM 8×8	(95, 81, 59)	0,1609	0,0101	669
SOM 16×16	(109, 94, 74)	0,0840	0,0062	163
GNG 16	(109, 92, 71)	0,0882	0,0151	288
GNG 64	(118, 100, 81)	0,0601	0,0113	96
GNG 256	(123, 105, 86)	0,0666	0,0075	60

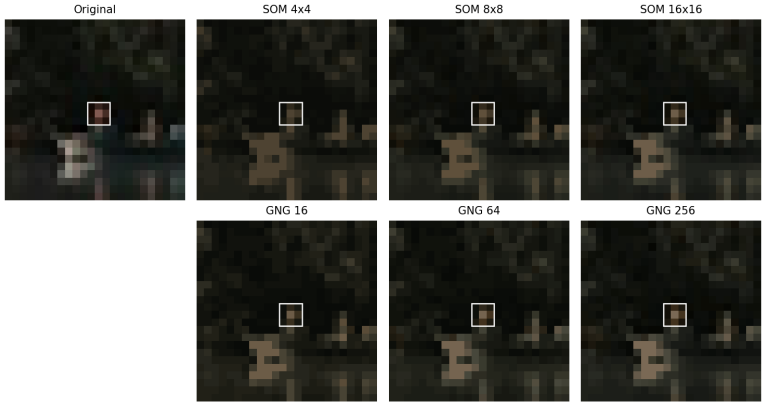


Figura 4: Região de 24×24 pixels em volta do pixel de cor rara (quadrado branco), ampliada.

neurônios, a cor recebida se aproxima da original e o BMU passa a ser compartilhado com menos pixels (de 2312 para 60), mas nenhuma rede criou um neurônio avermelhado. **Por quê:** o detalhe ocupa poucos pixels entre 40.000, e os neurônios se deslocam para onde há muitas amostras.

4. Uso dos Neurônios (Hit Maps)

O *hit map* mostra **quantos pixels cada neurônio captura**, isto é, para quantos pixels ele é o BMU. A Figura 5 mostra os *hit maps* da imagem 2, a mais colorida. Como ler:

- **SOM (linha de cima):** cada célula é um neurônio, na sua posição no grid, pintada com a cor do neurônio; o número é a quantidade de pixels que ele captura.
- **GNG (linha de baixo):** a GNG não tem grid, então cada barra é um neurônio, pintada com a sua cor. As barras estão ordenadas do neurônio mais usado para o menos usado, e a altura (em escala log) é o número de pixels.

O que a figura mostra:

- **Organização do SOM.** Células vizinhas têm cores parecidas: no grid 4×4, os tons claros do céu ficam no canto superior esquerdo, os tons avermelhados (cachorro, casaco rosa) à direita e os escuros no canto inferior direito. A cor muda aos poucos pelo grid, também no 8×8 e no 16×16. Isso é a preservação topológica, e combina com o ET baixo do SOM nessa imagem (0,0026 no 4×4).
- **Cores ausentes no SOM 4×4.** Nenhuma das 16 células é azul ou roxa, o que explica por que os casacos mudaram de cor na Figura 1. Na GNG 16, há uma barra azul-marinho e uma roxa (a menor de todas): a GNG reservou neurônios para essas cores, embora sejam pouco frequentes.
- **Distribuição do uso.** No SOM 4×4, o neurônio mais usado (cinza-claro, céu) captura 5117 pixels, 12,8% da imagem. Na GNG 16, o uso fica mais equilibrado, e o neurônio roxo é o menos

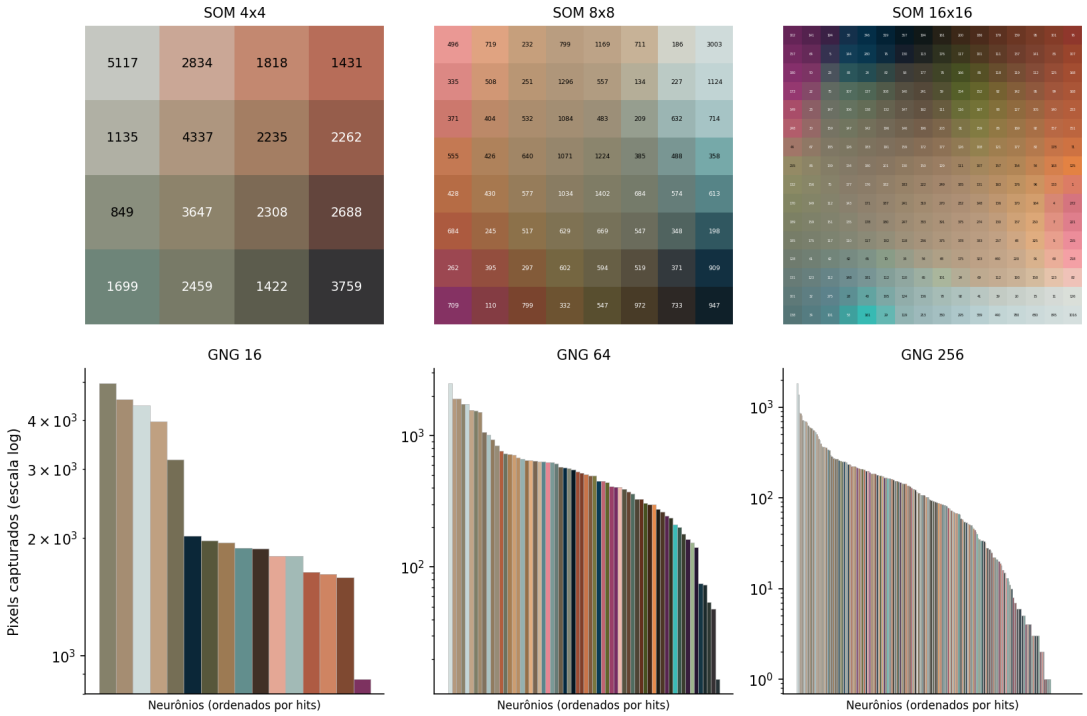


Figura 5: *Hit maps* da imagem 2. SOM: células do grid com a cor do neurônio e o número de pixels capturados. GNG: uma barra por neurônio, ordenadas do mais usado ao menos usado (escala log).

usado. Na GNG 256, o uso cai de forma contínua da esquerda para a direita, e o espaço vazio à direita das barras corresponde a **neurônios que não capturam nenhum pixel**.

A Tabela 4 resume o uso dos neurônios nas 5 imagens.

Tabela 4: Porcentagem dos pixels capturada pelo neurônio mais usado de cada rede e número de neurônios da GNG 256 sem nenhum pixel. Nas demais redes, todos os neurônios capturam ao menos um pixel.

	% dos pixels no neurônio mais usado						Sem pixels
Imagem	SOM 4×4	SOM 8×8	SOM 16×16	GNG 16	GNG 64	GNG 256	GNG 256
1. Lago/floresta	24,4	7,7	3,4	17,3	12,1	4,9	52
2. Crianças/cachorro	12,8	7,5	2,5	12,4	6,3	4,6	17
3. Cidade à noite	29,4	9,1	2,9	21,9	19,3	12,6	46
4. Pôr do sol	16,8	3,4	0,9	12,3	5,8	3,1	29
5. Flores/porta	16,9	9,0	2,5	12,7	9,2	6,9	27

- **Imagens escuras concentram pixels num só neurônio.** Nas imagens 1 e 3, o neurônio mais usado do SOM 4×4 (uma cor quase preta) captura 24,4% e 29,4% dos pixels: o fundo escuro ocupa boa parte dessas imagens.
- **Com 256 cores, a GNG concentra mais pixels no neurônio mais usado que o SOM**, em todas as imagens (na imagem 3, 12,6% contra 2,9%); com 64 cores, isso ocorre em 4 das 5 imagens. Uma explicação provável é que a GNG insere neurônios onde o erro acumulado é maior, e uma região grande e uniforme, como o céu noturno, acumula pouco erro e pode ficar com um único neurônio.
- **Neurônios sem uso na GNG 256.** Em todas as imagens, entre 17 e 52 neurônios da GNG 256 não capturam nenhum pixel, enquanto o SOM usa todos os neurônios. Uma explicação provável é que cada neurônio novo da GNG nasce no ponto médio entre dois neurônios, e esse

ponto pode cair numa região de cor sem pixels. Isso ajuda a explicar por que, com 256 cores, o SOM teve EQ menor.

5. Variações: Vizinhança e Taxas

As variações foram rodadas nas imagens 1 e 4, mudando um parâmetro por vez em relação à configuração base (Tabela 5). Na vizinhança **bubble**, todos os neurônios a menos de σ do vencedor no grid recebem o mesmo ajuste e os demais nenhum. No MiniSom, essa região é um quadrado em volta do vencedor.

Tabela 5: Variações nas imagens 1 e 4 (EQ e ET). A linha "base" repete a Tabela 2.

		SOM 4×4		**SOM 8×8**		**SOM 16×16**	
Img.	**Variação**	EQ	ET	EQ	ET	EQ	ET
1	base (gaussiana, $\sigma_0 = 2$, $\eta_0 = 0{,}1$)	0,0175	0,1588	0,0101	0,0461	0,0062	0,1752
1	bubble	0,0152	0,0231	0,0091	0,3323	0,0057	0,3287
1	$\sigma_0 = 1$	0,0152	0,1210	0,0091	0,2199	0,0058	0,2725
1	$\sigma_0 = 4$	0,0289	0,0449	0,0123	0,2179	0,0076	0,1196
1	$\eta_0 = 0{,}01$	0,0179	0,0859	0,0102	0,1674	0,0065	0,1500
1	$\eta_0 = 0{,}5$	0,0192	0,0921	0,0103	0,2581	0,0064	0,0853
4	base (gaussiana, $\sigma_0 = 2$, $\eta_0 = 0{,}1$)	0,0405	0,0016	0,0210	0,0249	0,0117	0,0265
4	bubble	0,0338	0,1605	0,0185	0,1516	0,0104	0,1658
4	$\sigma_0 = 1$	0,0343	0,0431	0,0182	0,0767	0,0104	0,1684
4	$\sigma_0 = 4$	0,0818	0,0208	0,0274	0,0190	0,0145	0,0267
4	$\eta_0 = 0{,}01$	0,0420	0,0618	0,0210	0,0278	0,0124	0,0750
4	$\eta_0 = 0{,}5$	0,0428	0,0054	0,0212	0,0381	0,0117	0,0416
		GNG 16		**GNG 64**		**GNG 256**	
1	base	0,0151	0,0000	0,0113	0,0002	0,0075	0,0016
1	$\eta_b = 0{,}005$	0,0149	0,0000	0,0111	0,0001	0,0084	0,0012
1	$\eta_b = 0{,}05$	0,0155	0,0006	0,0099	0,0006	0,0064	0,0044
1	$\eta_n = 0{,}001$	0,0149	0,0000	0,0104	0,0001	0,0075	0,0012
1	$\lambda = 25$	0,0150	0,0001	0,0100	0,0007	0,0078	0,0012
1	$\lambda = 100$	0,0153	0,0005	0,0118	0,0021	0,0074	0,0019
4	base	0,0338	0,0008	0,0192	0,0033	0,0124	0,0027
4	$\eta_b = 0{,}005$	0,0336	0,0000	0,0198	0,0014	0,0134	0,0022
4	$\eta_b = 0{,}05$	0,0342	0,0000	0,0185	0,0023	0,0115	0,0058
4	$\eta_n = 0{,}001$	0,0353	0,0001	0,0193	0,0014	0,0119	0,0027
4	$\lambda = 25$	0,0338	0,0008	0,0188	0,0017	0,0121	0,0041
4	$\lambda = 100$	0,0337	0,0006	0,0189	0,0014	0,0125	0,0029

Gaussiana vs. bubble. A bubble teve **EQ menor em todos os casos**, mas **ET muito maior** em 5 dos 6 (na imagem 4, de 0,0016 para 0,1605 no grid 4×4); a exceção foi o grid 4×4 da imagem 1. **Por quê:** na bubble, quando σ cai abaixo de 1, só o vencedor aprende, e o mapa para de se organizar mais cedo. Cada neurônio fica livre para se ajustar à sua cor (EQ menor), mas neurônios vizinhos no grid deixam de ter cores parecidas (ET maior). Na gaussiana, os vizinhos continuam recebendo um ajuste menor até o fim, o que mantém o mapa organizado.

Raio inicial σ_0. $\sigma_0 = 1$ (menos cooperação entre vizinhos) se comporta como a bubble: EQ menor em todos os casos e ET maior em 5 dos 6. $\sigma_0 = 4$ (mais cooperação) aumentou o EQ em todos os casos (na imagem 4, grid 4×4, de 0,0405 para 0,0818), mas não reduziu o ET de forma consistente. **Há uma troca entre EQ e ET**: menos cooperação dá cores mais precisas e um mapa menos organizado; $\sigma_0 = 2$ ficou no meio-termo.

Taxa de aprendizado do SOM (η_0). A taxa base, 0,1, teve EQ igual ou menor que 0,01 e 0,5 em todos os casos, mas as diferenças são pequenas (a maior foi no grid 4×4 da imagem 4: 0,0405 contra 0,0428 com $\eta_0 = 0{,}5$). O ET do SOM mudou bastante entre as taxas, sem uma direção clara.

Taxas e λ da GNG. Com $\eta_b = 0{,}05$ (o vencedor se move mais), o EQ caiu nas redes de 64 e 256 neurônios (imagem 1, GNG 256: de 0,0075 para 0,0064), e o ET aumentou em 3 desses 4 casos. Com $\eta_b = 0{,}005$, o EQ da GNG 256 piorou nas duas imagens. A taxa dos vizinhos $\eta_n = 0{,}001$ e as mudanças

de λ alteraram pouco o EQ e sem direção consistente: com 5 passagens pelos dados, a rede atinge o número alvo de neurônios em qualquer caso e depois só se adapta. **Os valores base da GNG funcionaram bem** e não precisaram de ajuste.

6. Discussão e Conclusões

- **SOM (rede fixa) vs. GNG (topologia adaptativa).** Com poucas cores, a GNG representa melhor as imagens, porque coloca neurônios onde o erro é grande e mantém as cores saturadas de áreas pequenas, que o SOM 4×4 perde. Com 256 cores, o SOM 16×16 fica um pouco à frente, em parte porque alguns neurônios da GNG 256 ficam sem uso. O SOM, por sua vez, organiza as cores no grid de forma que neurônios vizinhos tenham cores parecidas, como se vê nos *hit maps*.

- **Número de cores.** 16 cores bastam para reconhecer as imagens, mas criam faixas nos degradês (imagem 4) e trocam as cores de detalhes (imagens 2, 3 e 5). Com 64 cores o resultado já é bom, e com 256 fica praticamente igual ao original.

- **Cores raras desaparecem.** Detalhes de cor muito pouco frequentes, como a pessoa avermelhada da imagem 1, não ganham um neurônio próprio em nenhuma rede.

- **Vizinhança e taxas.** A vizinhança gaussiana preserva melhor a topologia que a bubble, ao custo de um EQ um pouco maior. As taxas de aprendizado tiveram efeito pequeno no EQ dentro dos valores testados.