Projeto 3: Modelos Generativos

Autoencoder Variacional (VAE) no Fashion-MNIST

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Arthur Santos de Oliveira (RA: 156297)

Repositório / Código Reprodutível:

https://github.com/Arthur-so/introducao-a-redes-neurais

---

1. Configuração Experimental

1.1. Dados e Partição

O Fashion-MNIST tem 70.000 imagens de roupas e acessórios em tons de cinza, com 28×28 pixels, divididas em 10 classes: camiseta, calça, suéter, vestido, casaco, sandália, camisa, tênis, bolsa e bota. Cada imagem foi achatada num vetor de 784 pixels, e cada pixel foi dividido por 255 para ficar em $[0, 1]$. A partição usada foi:

- **Treino:** 50.000 imagens, sorteadas das 60.000 de treino do conjunto original;
- **Validação:** as outras 10.000 imagens de treino, usadas para escolher a topologia;
- **Teste:** as 10.000 imagens de teste originais, usadas só na avaliação final e nos gráficos do espaço latente.

Os rótulos não são usados no treino. Eles servem apenas para pintar os pontos nos gráficos do espaço latente.

1.2. Modelo e Função de Custo

O VAE tem duas redes MLP. O **codificador** recebe a imagem x e devolve a média μ_x e o desvio padrão σ_x de uma distribuição normal no espaço latente; na prática, a rede devolve $\log \sigma_x^2$, que pode assumir qualquer valor real. Um ponto é sorteado dessa distribuição pelo **truque de reparametrização**, $z = \mu_x + \sigma_x \zeta$, com $\zeta \sim N(0, I)$, e o **decodificador** reconstrói a imagem $d(z)$ a partir dele. A saída do decodificador passa por uma sigmoide, para ficar em $[0, 1]$, como os pixels.

A função de custo de cada imagem é a soma de dois termos:

$$\text{custo} = \underbrace{\|x - d(z)\|^2}_{\text{reconstrução}} + \underbrace{KL(N(\mu_x, \sigma_x), N(0, I))}_{\text{regularização}}, \qquad KL = -\frac{1}{2} \sum_{j=1}^{k} \left(1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2\right),$$

em que a reconstrução soma o erro quadrático dos 784 pixels e k é a dimensão do espaço latente. O custo de um conjunto é a média do custo das suas imagens. O termo KL puxa a distribuição de cada imagem para perto da normal padrão $N(0, I)$, o que mantém o espaço latente contínuo e permite gerar imagens novas sorteando $z \sim N(0, I)$.

1.3. Hiperparâmetros e Busca da Topologia

Para cada dimensão latente (2 e 8), foram treinadas 5 topologias, variando o número de camadas ocultas (1, 2 ou 3) e a largura (256 ou 512 neurônios na primeira camada). O decodificador usa as mesmas camadas do codificador, em ordem inversa. A topologia escolhida para cada dimensão foi a de **menor custo na validação**. Os demais hiperparâmetros ficaram fixos, com valores mais utilizados (Tabela 1).

Tabela 1: Espaço de busca e hiperparâmetros fixos.

Item	Valor
Topologias do codificador	784-256; 784-512; 784-256-128; 784-512-256; 784-512-256-128
Dimensão latente	2 e 8 (busca feita separadamente para cada uma)
Ativação	ReLU nas camadas ocultas; sigmoide na saída do decodificador
Otimizador	Adam, taxa de aprendizado 10^{-3}
Tamanho do lote	128
Épocas	30; ficam os pesos da época de menor custo na validação
Semente	42

2. Escolha da Topologia

A Tabela 2 traz o custo na validação de cada topologia, na sua melhor época, separado nos dois termos. A Figura 1 mostra o custo na validação ao longo das épocas.

Tabela 2: Busca da topologia: custo na validação na melhor época (menor é melhor). Em negrito, a topologia escolhida para cada dimensão latente.

Latente	Codificador	Parâmetros	Melhor época	Custo	Reconstrução	KL
2D	784-256	404.244	30	28,03	23,18	4,85
2D	784-512	807.700	30	27,86	23,09	4,77
2D	784-256-128	469.268	30	26,24	21,10	5,14
2D	784-512-256	1.068.820	28	25,91	20,59	5,32
2D	**784-512-256-128**	**1.133.844**	**21**	**25,86**	**20,77**	**5,10**
8D	784-256	408.864	29	24,33	15,80	8,54
8D	784-512	816.928	30	23,97	15,66	8,31
8D	784-256-128	471.584	26	23,74	16,90	6,83
8D	**784-512-256**	**1.073.440**	**30**	**23,38**	**16,27**	**7,10**
8D	784-512-256-128	1.136.160	30	23,83	17,59	6,24

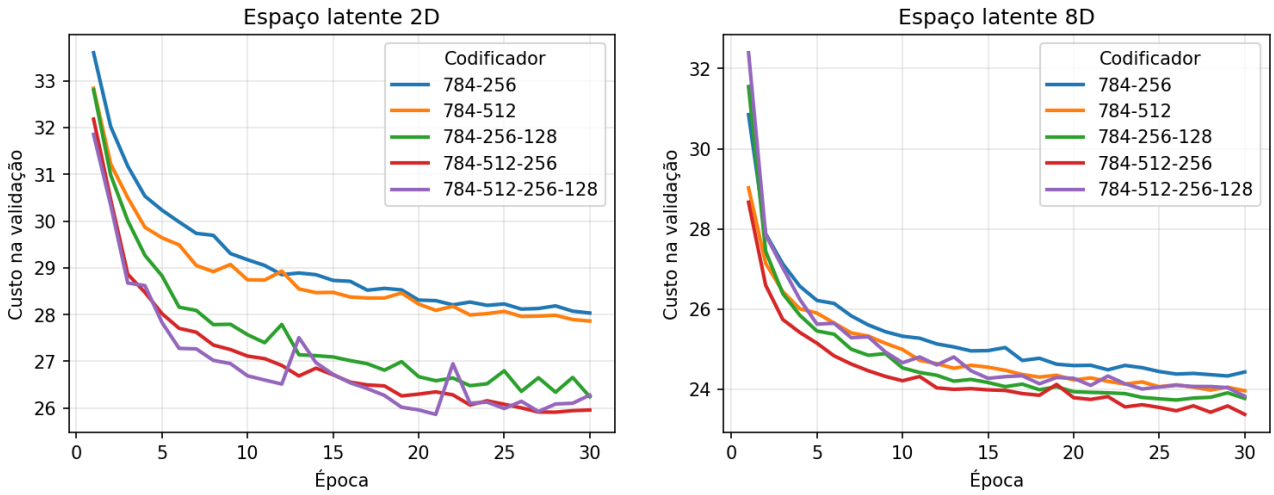


Figura 1: Custo na validação por época de cada topologia. Esquerda: espaço latente 2D; direita: 8D.

- **Topologias escolhidas.** No espaço 2D, a melhor foi a de 3 camadas (784-512-256-128, custo 25,86); no 8D, a de 2 camadas (784-512-256, custo 23,38). No 2D, a diferença para a segunda colocada (784-512-256, 25,91) é de apenas 0,05, um empate na prática.
- **Profundidade pesou mais que largura.** No 2D, passar de 1 para 2 camadas reduziu o custo em cerca de 1,8 (de 28,03 para 26,24 com 256 neurônios), enquanto dobrar a largura da rede

de 1 camada (de 256 para 512) reduziu só 0,17. No 8D, as diferenças entre topologias foram menores (de 23,38 a 24,33), e a rede de 3 camadas ficou atrás da de 2.

- **8D teve custo menor que 2D em todas as topologias.** A diferença está na reconstrução: entre 15,66 e 17,59 no 8D, contra 20,59 a 23,18 no 2D. Em compensação, o KL é maior no 8D (6,24 a 8,54, contra 4,77 a 5,32).

Por quê. Com 8 dimensões, o codificador pode guardar mais informação sobre cada imagem, e o decodificador a reconstrói melhor. Cada dimensão que se afasta de $N(0, 1)$ aumenta o termo KL, então o ganho na reconstrução vem com um KL maior. Com 2 dimensões, a rede precisa comprimir muito a imagem, e camadas a mais ajudam a fazer essa compressão.

A Figura 2 mostra as curvas de treino e validação dos dois modelos escolhidos.

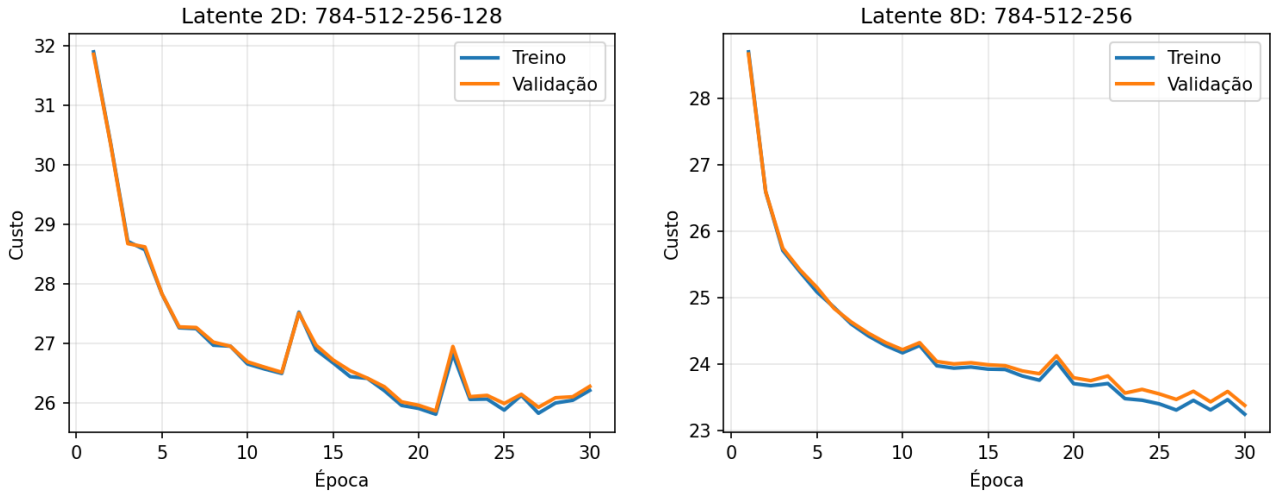


Figura 2: Custo de treino e de validação por época dos modelos escolhidos.

- **Não houve sobreajuste.** As curvas de treino e validação ficam praticamente sobrepostas nos dois modelos durante as 30 épocas.
- **Picos no modelo 2D.** O modelo de 3 camadas teve dois saltos no custo (épocas 13 e 22), dos quais se recuperou nas épocas seguintes. Por isso a sua melhor época foi a 21, e não a última.
- **O custo ainda caía na época 30.** Na maioria das topologias, a melhor época ficou entre a 28 e a 30 (Tabela 2). Mais épocas provavelmente reduziriam um pouco o custo, mas a comparação entre topologias foi feita com o mesmo número de épocas para todas.

Conjunto de teste. A Tabela 3 mostra o custo dos modelos escolhidos no teste. Os valores ficaram próximos dos da validação (25,86 e 23,38), o que confirma que não houve sobreajuste.

Tabela 3: Custo dos modelos escolhidos no conjunto de teste.

Latente	Codificador	Custo	Reconstrução	KL
2D	784-512-256-128	25,98	20,90	5,08
8D	784-512-256	23,52	16,45	7,07

3. Reconstrução e Geração de Imagens

A Figura 3 mostra a primeira imagem de cada classe do conjunto de teste e a sua reconstrução pelos dois modelos (decodificando a média μ_x).

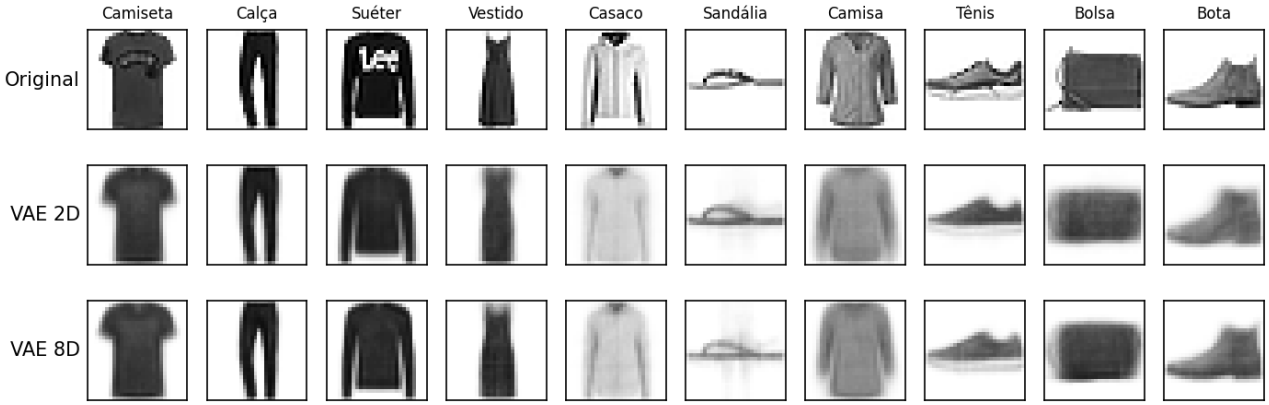


Figura 3: Uma imagem de teste de cada classe (linha de cima) e as reconstruções dos VAEs 2D e 8D.

Os dois modelos reconstroem a **forma e o tom geral** de todas as peças, mas as imagens ficam borradas e perdem detalhes finos: a estampa da camiseta, as letras do suéter, os detalhes do casaco e a alça da bolsa. A diferença visual entre 2D e 8D é pequena nesses exemplos, embora o erro de reconstrução no teste seja bem menor no 8D (16,45 contra 20,90).

A Figura 4 mostra imagens **novas**, geradas decodificando 10 pontos sorteados de $N(0, I)$ em cada modelo.

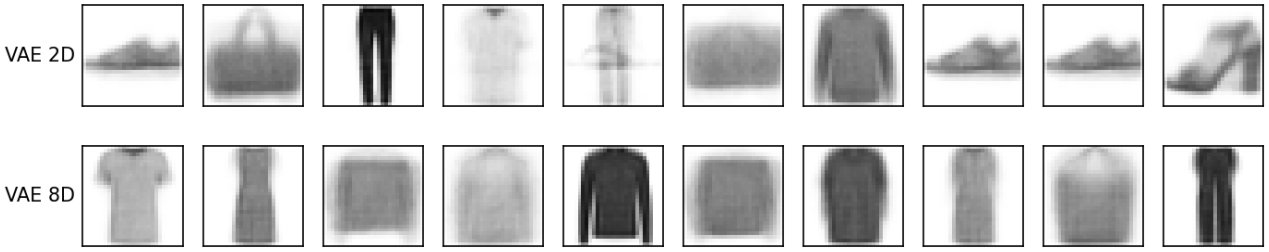


Figura 4: Imagens geradas a partir de $z \sim N(0, I)$, sem usar nenhuma imagem de entrada.

A maioria das imagens geradas é reconhecível como uma peça do conjunto: tênis, bolsas, calças, camisetas, suéteres e vestidos. A exceção é a 5ª imagem do modelo 2D, que mistura uma peça de roupa com uma sandália. Esse tipo de imagem aparece quando o ponto sorteado cai entre dois grupos do espaço latente (Seção 4).

4. Espaço Latente 2D

A Figura 5 mostra a representação latente (μ_x) das 10.000 imagens de teste no modelo 2D, com cada ponto pintado pela classe da imagem.

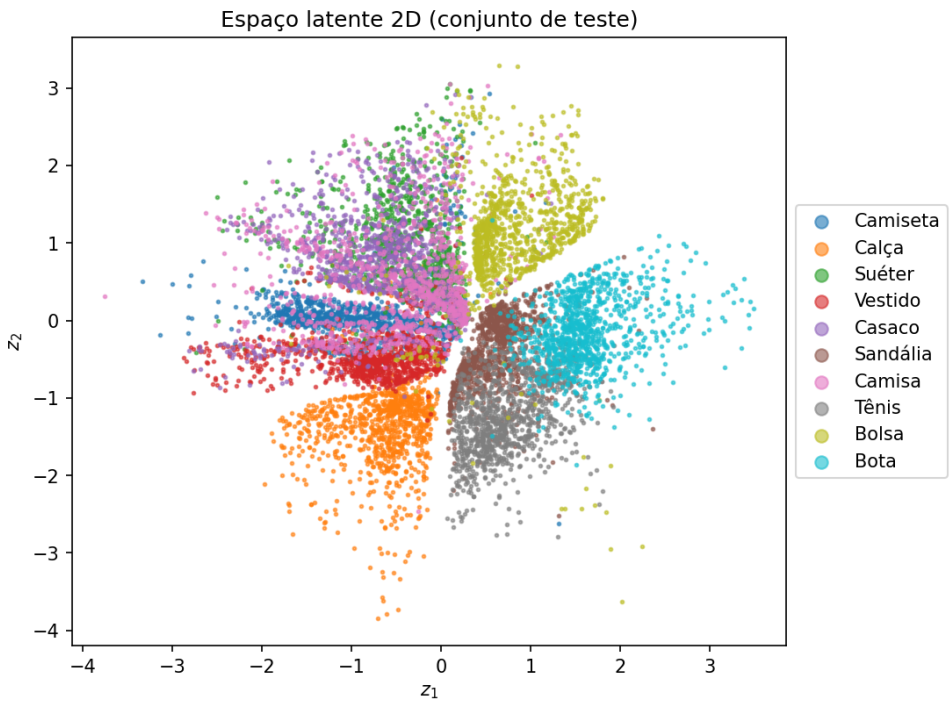


Figura 5: Espaço latente 2D: média μ_x de cada imagem de teste, pintada pelo rótulo.

- **Há formação de clusters.** Os calçados (sandália, tênis e bota) ocupam a parte direita e inferior direita; as bolsas, a parte superior direita; as calças, a parte inferior esquerda; e as peças que cobrem o tronco (camiseta, suéter, casaco, camisa e vestido), a metade esquerda.
- **A separação dos rótulos depende da classe.** Calça, bolsa, bota e tênis formam grupos bem separados. A sandália fica entre o tênis e a bota, encostada nos dois. Camiseta e vestido formam faixas próprias, mas encostadas uma na outra. **Suéter, casaco e camisa ficam misturados** na parte superior esquerda.
- **Distribuição perto da normal padrão.** Quase todos os pontos ficam entre -3 e 3 nos dois eixos, centrados na origem, como o termo KL incentiva.

Por quê. O VAE agrupa imagens parecidas, pois imagens próximas no espaço latente geram reconstruções parecidas. Suéter, casaco e camisa têm a mesma silhueta (tronco com manga comprida) e diferem em detalhes finos, que o modelo 2D não consegue representar (Figura 3). Por isso essas classes se sobrepõem. A calça, a bolsa e os calçados têm formas bem diferentes de todas as outras classes, e por isso ficam separados.

A Figura 6 decodifica uma grade de 15×15 pontos do espaço latente, de -3 a 3 em cada eixo. Cada imagem está na posição (z_1, z_2) que a gerou, e a figura pode ser comparada diretamente com a Figura 5.

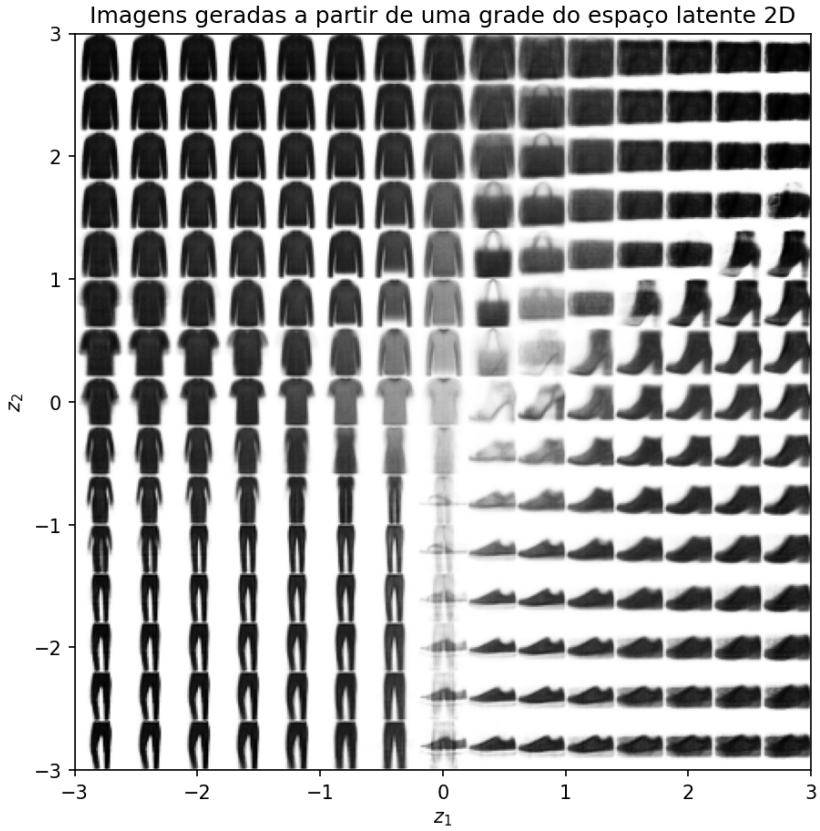


Figura 6: Imagens geradas pelo decodificador do modelo 2D numa grade de pontos do espaço latente.

- **As regiões batem com os clusters.** Peças de manga comprida no alto à esquerda, camisetas e vestidos no meio à esquerda, calças embaixo à esquerda, bolsas no alto à direita, botas no meio à direita e tênis embaixo à direita.
- **O espaço é contínuo.** As imagens mudam aos poucos entre pontos vizinhos: o suéter encurta a manga e vira camiseta, a camiseta afina e vira vestido, e a bota vira um sapato de salto e depois uma sandália.
- **Regiões entre grupos geram imagens misturadas.** Em $z_1 \approx 0$, abaixo de $z_2 = -1$, entre as calças e os tênis, as imagens são borradas e misturam as duas peças. Na Figura 5, essa é uma faixa com poucas imagens de teste.

5. Espaço Latente 8D Projetado com PCA

Para visualizar o espaço 8D, a média μ_x das imagens de teste foi projetada nas duas primeiras componentes principais (PCA). A Figura 7 mostra a projeção com os rótulos, e a Figura 8 mostra a fração da variância explicada por cada componente.

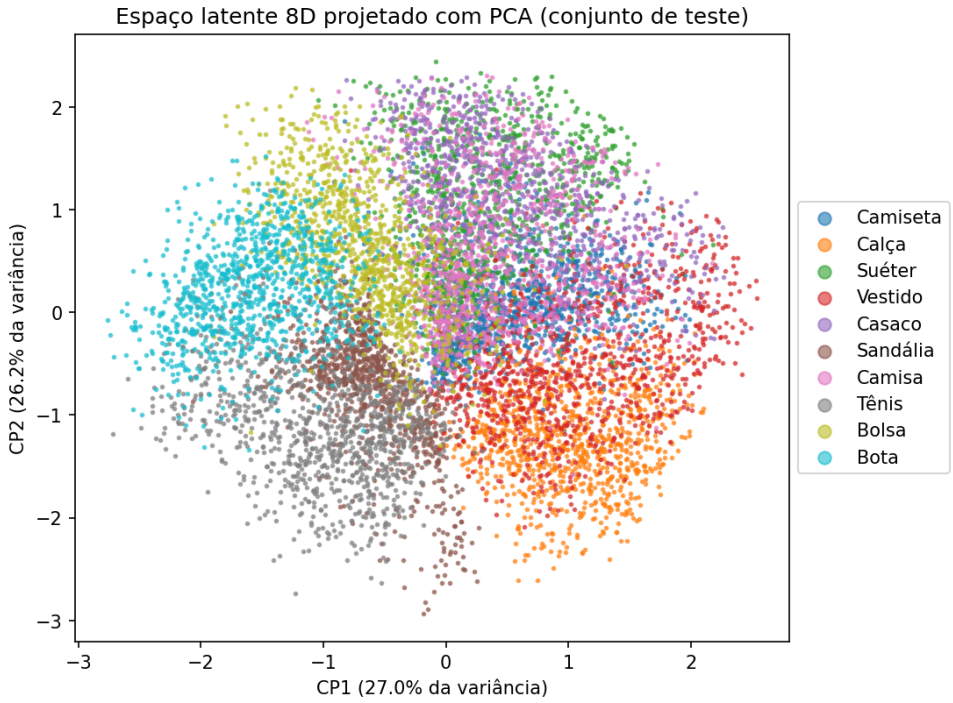


Figura 7: Espaço latente 8D projetado nas duas primeiras componentes principais (CP1 e CP2), pintado pelo rótulo.

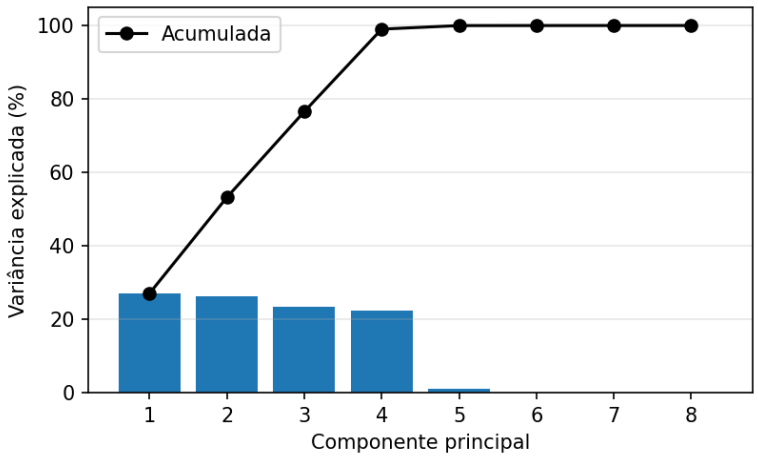


Figura 8: Variância explicada por cada componente principal do espaço latente 8D (barras) e acumulada (linha).

A projeção ilustra 53,2% da variância: 27,0% na CP1 e 26,2% na CP2. As componentes 3 e 4 explicam quase o mesmo (23,4% e 22,5%), e as quatro primeiras juntas chegam a 99,0%. As componentes 5 a 8 somam menos de 1%.

Por que só 4 componentes importam. O modelo 8D usa só 4 das suas 8 dimensões latentes (Tabela 4). Nas dimensões 1, 3, 5 e 8, a média μ fica praticamente igual para todas as imagens (variância de no máximo 0,036) e o desvio σ fica perto de 1, ou seja, a distribuição dessas dimensões é a própria $N(0, 1)$ e não carrega informação sobre a imagem. Como o termo KL cobra por cada dimensão que se afasta de $N(0, 1)$, o modelo só usa uma dimensão se ela melhorar a reconstrução o bastante, e 4 dimensões foram suficientes.

Tabela 4: Uso de cada dimensão do espaço latente 8D nas imagens de teste: variância de μ entre as imagens e σ médio.

Dimensão	1	2	3	4	5	6	7	8
Variância de μ	0,000	0,844	0,001	0,994	0,001	0,974	0,883	0,036
σ médio	0,999	0,267	0,988	0,124	1,001	0,121	0,276	0,975

- **Há formação de clusters**, nas mesmas famílias do espaço 2D: calçados à esquerda (bota, sandália e tênis), bolsas acima deles, calças e vestidos embaixo à direita e as peças de tronco no alto, no centro.
- **A separação na projeção é menor que no espaço 2D.** Os grupos se encostam mais: bolsa toca a bota e as peças de tronco, vestido se mistura com calça e com camiseta, e camiseta, suéter, casaco e camisa se sobrepõem no centro.
- **Cuidado com a leitura.** A projeção mostra só 53,2% da variância. Pontos que se sobrepõem na projeção podem estar separados nas componentes 3 e 4, que juntas têm outros 45,8%. Já no modelo 2D, o gráfico mostra o espaço latente inteiro.

6. Discussão e Conclusões

- **Há formação de clusters no espaço latente?** Sim, nos dois modelos. As imagens se agrupam por forma: calçados, bolsas, calças e peças de tronco ocupam regiões diferentes, mesmo sem os rótulos serem usados no treino.
- **Há separação dos rótulos?** Parcial. Calça, bolsa, bota e tênis ficam bem separados; sandália, camiseta e vestido ficam encostados nos grupos vizinhos; suéter, casaco e camisa se misturam, pois têm a mesma silhueta. A separação é mais clara no gráfico 2D do que na projeção do 8D.
- **Quanto da variância a projeção ilustra?** 53,2% (27,0% + 26,2%). O modelo 8D usa apenas 4 dimensões, e as 4 primeiras componentes somam 99,0% da variância.
- **2D vs. 8D.** O modelo 8D teve custo menor (23,52 contra 25,98 no teste), graças a uma reconstrução melhor, mas ainda assim usou só 4 das 8 dimensões. O modelo 2D reconstrói pior, mas o seu espaço latente pode ser visto por inteiro e percorrido diretamente (Figura 6).
- **Topologia.** Para o espaço 2D, redes mais profundas reduziram bem o custo; para o 8D, as diferenças entre topologias foram pequenas, e a rede de 2 camadas foi a melhor.
- **Limitações.** As imagens reconstruídas e geradas são borradas e sem detalhes finos. O custo ainda caía na época 30 em quase todas as topologias, e a diferença entre as duas melhores topologias do 2D (0,05) é pequena demais para apontar uma vencedora clara com uma única semente.